

2018 届硕士研究生学位论文

分类号: _____

学校代码: 10269

密 级: _____

学号: 51151214015

華東師範大學

East China Normal University

硕士学位论文

MASTER'S DISSERTATION

论文题目: 基于显微高光谱成像的皮肤黑
色素瘤识别方法研究

院 系: 信息科学技术学院通信工程系

专 业: 信号与信息处理

研究方向: 模式识别与智能系统

指导教师: 李庆利 教授

论文作者: 黄怡

2018 年 4 月

Dissertation for master degree in 2018

Univ. ID: 10269

East China Normal University

Student ID:51151214015

East China Normal University

**Title: The research on the identification of
skin melanoma based on microscopic
hyperspectral imaging**

Department: Communication Engineering

Major: Signal and information processing

Specialty: Pattern recognition and intelligent system

Supervisor: Prof. Qingli Li

Candidate: Yi Huang

April 2018

黄怡 硕士学位论文答辩委员会成员名单

姓名	职称	单位	备注
李明	教授	华东师范大学	答辩主席
黄昶	副教授	华东师范大学	
孙力	副教授	华东师范大学	

摘 要

皮肤黑色素瘤是一种恶性程度极高的皮肤肿瘤，现阶段尚无治愈手段，但早期确诊能够让患者得到最佳的手术时机，从而延长了患者术后的存活时间。因此，研究皮肤黑色素瘤的早期诊断方法对于临床治疗和预后都具有重要的意义。传统的皮肤黑色素瘤病理诊断对肿瘤组织无辅助识别方法和量化分析，针对这个问题，本文将显微高光谱成像技术用于皮肤黑色素瘤的识别和量化分析，为皮肤黑色素瘤的病理诊断分析提供一种新的方法。根据皮肤黑色素瘤样本的多样性，本文将其分为典型的三类，针对不同类型的样本，提出了不同的研究方法。本文的主要研究内容如下：

首先，从组织学层次，研究了皮肤颗粒层的分割问题，提出了基于核最小噪声分离(KMNF)的分割方法。在该方法中，采用 KMNF 来提取显微高光谱图像的主要特征并分离图像中的噪声，然后使用形态学滤波来获得颗粒层的主要形态特征，最后应用水平集分割方法来得到颗粒层的形态轮廓。实验结果显示，该方法分割皮肤颗粒层的精度高达 80%以上，为皮肤黑色素瘤入侵深度的计算提供起始边界。

其次，研究了恶性黑色素细胞的分割问题，提出了基于特征光谱监督的最小二乘支持向量机(CSS-LSSVM)分割方法。在该方法中，使用最小二乘支持向量机(LSSVM)算法来建立恶性黑色素细胞的分割模型，并在传统的 LSSVM 算法基础上，选取目标样本少数特征光谱作为参考，对 LSSVM 模型分割结果进行再分割以提高模型的分割精度。实验结果表明，该方法对皮肤黑色素瘤样本中的恶性黑色素细胞分割精度高达 85%以上。同时，该方法用于分割样本中的恶性黑色素细胞，结合颗粒层的分割结果，计算了样本的皮肤黑色素瘤入侵深度。

最后，研究了肿瘤区域的识别问题，采用了基于粒子群优化的极限学习机(PSO-ELM)分类算法。在该方法中，使用了极限学习机(ELM)来建立肿瘤区域识别模型，在极限学习机的参数寻优中，采用了粒子群(PSO)优化算法来寻找 ELM 参数的更优解，提高了极限学习机的分类精度。实验结果表明，该方法能够更有

效地识别出样本中的肿瘤区域，且分类速度比 SVM 快，将该方法用于肿瘤区域的自动识别，可提高皮肤黑色素瘤病理诊断的效率。

上述结果验证了显微高光谱成像技术在皮肤黑色素瘤识别中的可行性，并为其病理诊断提供了定量化数据，对皮肤黑色素瘤的临床治疗和预后都具有重要的意义。

关键词：显微高光谱成像，皮肤黑色素瘤，图像分割，图像分类

ABSTRACT

Cutaneous Malignant Melanoma is a kind of highly malignant skin tumors. Although there is no cure at current stage, early diagnosis can be helpful for patient to get best timing of surgery, thus to help them to prolong their postoperative survival time. Therefore, research on the early diagnosis of Cutaneous Malignant Melanoma is of great significance. Since there is no quantitative analysis in the pathologic diagnosis of Cutaneous Malignant Melanoma, in this paper, hyperspectral imaging technology is applied in the recognition and quantitative analysis to provide a new method for early diagnosis. According to the variety of sample raw data, in this paper, target recognition and quantitative analysis is done for three typical Cutaneous Malignant Melanoma samples. The content of this paper is as follows:

Firstly, the segmentation problem of skin granular layer is studied based on KMNF method. In this method, KMNF is used to extract the main features and reduce the noise of hyperspectral images. Then, morphological filtering is used to extract the main morphological character of granular layer. Level set is subsequently applied to obtain the morphological outlet of granular layer. The experiment results show that the accuracy of this method is over eighty percent in extracting granular layer. Therefore, it is able to obtain clear outlet for invasion depth calculation, using this method.

Secondly, the segmentation problem of Cutaneous Malignant Melanoma is studied using LSSVM with characteristic spectrum supervision (CSS-LSSVM). In this method, LSSVM is used to establish the segmentation model of Cutaneous Malignant Melanoma. Based on the established LSSVM model, some typical characteristic spectrum of the target is chosen as reference to re-segment the model. The experiments results show that the accuracy of this method is over eighty five percent in segmenting the Cutaneous Malignant Melanoma. Furthermore, combining

with the above segmentation results of skin granular layer, the Melanoma Depth of Invasion is calculated.

Finally, the segmentation of tumor region is studied using PSO-ELM algorithm. In this method, ELM is applied to establish the segmentation model of tumor region. Besides, to improve the segmentation accuracy of the model, the PSO algorithm is used to find optimum solution for ELM parameter. The experiment results show that, comparing with traditional SVM, the proposed PSO-ELM method can obtain higher segmentation accuracy and speed. Therefore, by using this method in the auto recognition of tumor area, the diagnosis efficiency will be improved.

These above results also show that hyperspectral imaging technology can be used in the segmentation of Cutaneous Malignant Melanoma, provide quantitative data for its pathological diagnosis, and it has important significance for the clinical treatment and prognosis of Cutaneous Malignant Melanoma.

Keywords: microscope hyperspectral imaging, cutaneous malignant melanoma, image segmentation, image classification

目 录

摘 要	I
ABSTRACT	III
目 录	V
图目录	VII
表目录	IX
第一章 绪论	1
1.1 选题的背景	1
1.1.1 皮肤黑色素瘤	1
1.1.2 显微高光谱成像技术	4
1.2 选题的意义	5
1.3 国内外研究现状	7
1.3.1 皮肤黑色素瘤国内外研究现状	7
1.3.2 显微高光谱成像技术国内外研究现状	8
1.4 本文主要研究内容及结构安排	9
第二章 显微高光谱成像系统及皮肤黑色素瘤样本	12
2.1 显微高光谱成像系统	12
2.1.1 系统组成	12
2.1.2 系统性能指标	13
2.2 数据采集与光谱校正方法	14
2.2.1 数据采集及数据格式	14
2.2.2 高光谱图像样本校正	17
2.3 皮肤黑色素瘤样本制备和类型	20
2.3.1 皮肤黑色素瘤样本制备	20
2.3.2 皮肤黑色素瘤样本类型	21
2.4 本章小结	25
第三章 皮肤黑色素瘤显微高光谱图像识别方法	26
3.1 显微高光谱图像分割方法	26
3.1.1 基于 KMNF 的分割方法	26
3.1.1.1 高光谱图像特征提取	27
3.1.1.2 数学形态学滤波	30
3.1.1.3 基于水平集分割的图像边缘检测	31
3.1.2 基于特征光谱监督的 LSSVM 分割方法	36
3.1.2.1 基于最小二乘的支持向量机分割算法 (LSSVM)	36
3.1.2.2 特征光谱监督策略	39
3.2 基于 PSO 优化的极限学习机分类方法	40
3.3 定量化评价方法	45
3.4 本章小结	47
第四章 皮肤黑色素瘤识别及定量化分析	48

4.1 基于高光谱图像形态分割的皮肤颗粒层分割.....	48
4.1.1 病理图像分割结果.....	49
4.1.2 基于 KMNF 的分割结果.....	50
4.1.3 PCA、MNF、KMNF 分割结果对比.....	51
4.2 基于特征光谱监督的恶性黑色素细胞分割.....	54
4.3 基于 PSO-ELM 的皮肤黑色素瘤分类	58
4.4 皮肤黑色素瘤入侵深度测量方法.....	62
4.5 本章小结.....	66
第五章 总结与展望	67
5.1 总结.....	67
5.2 展望.....	68
参考文献	70
致谢	74
攻读硕士学位期间发表的学术论文	76
攻读硕士学位期间申请的发明专利	77
攻读硕士学位期间参与的科研项目	78

图目录

图 1-1 皮肤恶性黑色素瘤	2
图 1-2 2007-2013 年美国按年龄分组皮肤黑色素瘤比例	2
图 1-3 皮肤黑色素细胞痣和黑色素瘤病理样本	4
图 1-4 论文研究流程图	9
图 1-5 论文研究内容结构图	11
图 2-1 系数原理图	12
图 2-2 系统实物图	13
图 2-3 数据采集流程图	15
图 2-4 .raw 文件存储方式	16
图 2-5 .hdr 文件内容	16
图 2-6 高光谱数据立方图	17
图 2-7 入射光光路效果图	18
图 2-8 高光谱图像样本校正结果对比	19
图 2-9 正常皮肤组织显微视场	22
图 2-10 皮肤黑色素瘤样本类型 1	23
图 2-11 皮肤黑色素瘤样本类型 2	24
图 2-12 皮肤黑色素瘤样本类型 3	25
图 3-1 本节研究内容结构图	27
图 3-2 形态学滤波算子	31
图 3-3 基于特征光谱监督的 LSSVM 分割方法流程图	40
图 3-4 典型的单隐含层前馈神经网络结构图	41
图 3-5 粒子群算法对 ELM 模型的寻优流程	44
图 3-6 精度计算区域分布图	45
图 4-1 彩色图像处理结果	49
图 4-2 皮肤颗粒层分割结果	51

图 4-3 三种方法颗粒层分割结果对比图	52
图 4-4 PCA、MNF、KMNF 分割结果准确率对比图	54
图 4-5 恶性黑色素细胞分割结果	55
图 4-6 恶性黑色素细胞分割对比图	56
图 4-7 SVM 和 CSS-LSSVM 分割准确率对比图	58
图 4-8 样本 1 皮肤黑色素瘤分类结果	59
图 4-9 样本 2 皮肤黑色素瘤分类结果	61
图 4-10 颗粒层外边界与恶性黑色素细胞边界图	63
图 4-11 皮肤黑色素瘤入侵深度计算流程图	63
图 4-12 皮肤黑色素瘤入侵深度测量结果	65
图 4-13 多样本皮肤黑色素瘤入侵深度结果展示	65

表目录

表 1-1 2004-2011 年我国黑色素瘤发病情况 ^[4] (1/10 万)	3
表 4-1 皮肤颗粒层分割结果精度计算	53
表 4-2 恶性黑色素细胞分割结果精度	57
表 4-3 SVM 与 PSO-ELM 分类方法主要输入参数	58
表 4-4 样本 1 分类输入特征量与结果	60
表 4-5 样本 2 分类输入特征量与结果	62

第一章 绪论

1.1 选题的背景

1.1.1 皮肤黑色素瘤

恶性黑色素瘤(Malignant Melanoma, MM)是一种恶性程度较高的恶性肿瘤。近年来,恶性黑色素瘤发病率的年增长率为 3%-5%,是增长最快的恶性肿瘤。据统计,2012 年全球恶性黑色素瘤发病约 23.2 万例,死亡率达 23.7%。发达地区黑色素瘤男性和女性发病率分别为 10.2/10 万和 9.3/10 万,死亡率分别为 2.0/10 万和 1.2/10 万;欠发达地区的男女发病率分别为 0.8/10 万和 0.7/10 万,死亡率分别为 0.4/10 万和 0.3/10 万^[1]。恶性黑色素瘤的临床特点多样,起源不明,但多发生于皮肤部位,发生在皮肤部位的黑色素瘤称为皮肤黑色素瘤。

皮肤黑色素瘤(Cutaneous Malignant Melanoma, CMM)多源于表皮层的黑色素细胞癌变,是一种发病率较高的皮肤恶性肿瘤,其发病率随着年龄的增长逐渐提高,早期具有较高的转移力,患病死亡率较高^[2]。皮肤黑色素瘤大多数由色斑或者发育不良痣病变产生,主要发病于人体背部、肩部、下肢部位。在我国,皮肤黑色素瘤主要分为恶性雀斑样黑色素瘤、浅表扩散性恶性黑色素瘤、肢端恶性黑色素瘤和结节性恶性黑色素瘤,其中浅表扩散性恶性黑色素瘤和肢端恶性黑色素瘤如图 1-1 所示。图 1-1 中,(a)为浅表扩散性恶性黑色素瘤,呈现出侵袭性生长的大结节,结节周围围绕着斑片。(b)为肢端恶性黑色素瘤,肿瘤区域已经破坏了整个指甲,并向周围组织扩散,此类肿瘤发生时瘤体已经较厚,预后差。由此可见,皮肤黑色素瘤对皮肤的损害极其严重。




图 1-1 皮肤恶性黑色素瘤

皮肤黑色素瘤在过去的 50 年里发病率稳步上涨，主要为皮肤白皙的人群。根据世界卫生组织(World Health Organization, WHO)的 GLOBOCAN2012 数据库统计，2015 年全球皮肤黑色素瘤新增发病人数达到 250,178 例，其中男性 130,800 例，女性 119,378 例；2015 年全球皮肤黑色素瘤死亡人数 60,098 例，其中男性 34,143 例，女性 25,955 例。通过对国家、性别等全球性发病率的调查分析得出，大部分欧美国家发病率持续上升^[3]。基于 2012-2014 年统计数据，美国大约有 2.2% 的人诊断出患有皮肤黑色素瘤。皮肤黑色素瘤多发病于成人，偶尔发病于儿童，以美国为例，在 2007-2013 年这五年中，皮肤黑色素瘤新增病例占比与死亡占比按年龄分组如图 1-2 所示。




图 1-2 2007-2013 年美国按年龄分组皮肤黑色素瘤比例

由图 1-2 可知, 在 0-74 岁年龄段, 美国皮肤黑色素瘤的发病率和死亡率随着年龄的增长逐渐增加, 新增的皮肤黑色素瘤患者年龄大多分布在 55-74 岁, 因患皮肤黑色素瘤死亡的高发年龄段为 55-84 岁。

相比欧美国家, 亚洲国家皮肤黑色素瘤发病率相对较低, 但发病率增长速度较快。根据中国肿瘤登记报可得 2004-2011 年我国黑色素瘤发病情况如表 1-1 所示。

表 1-1 2004-2011 年我国黑色素瘤发病情况^[4](1/10 万)

年份	2004	2005	2006	2007	2008	2009	2011
总发病率	0.4/0.23	0.47/0.22	0.52/0.25	0.47/0.26	0.54/0.32	0.55/0.29	0.48/0.20
/死亡率							

批注: 中国肿瘤登记报 2004、2008、2009、2010、2011、2012 年

由表 1-1 可知, 2004-2011 年我国黑色素瘤总发病率维持在 0.4/10 万-0.55/10 万, 死亡率维持在 0.2/10 万-0.32/10 万。我国各地区皮肤黑色素瘤发病率差异较大, 男性发病率高于女性, 随着年龄的增长发病率增高, 多发于老龄人群及西北部地区^[5]。2011 年, 全国新增皮肤黑色素瘤 6505 例, 发病率为 0.48/10 万, 其中城市发病率为 0.58/10 万, 农村发病率为 0.38/10 万。根据中国肿瘤登记报^[4]统计, 2015 年, 我国皮肤黑色素瘤新增男性病例约 4,300 例, 女性约 3,700 例; 男性死亡病例约 1800 例, 女性死亡病例约 1500 例。可见, 皮肤黑色素瘤的发病率和死亡率呈现逐年增长的趋势, 因此, 进一步提高人们对该病的认知水平和治疗水平具有重要的意义。

皮肤黑色素瘤的治疗过程主要分为诊断、治疗和预后, 大多数病例确诊时已经是晚期, 而晚期皮肤黑色素瘤尚无有效的治愈手段, 通常只能通过手术切除、化疗等治疗手段延长患者的寿命。早期皮肤黑色素瘤确诊能够极大提高患者的治愈几率, 因此早期诊断极其重要。皮肤黑色素瘤早期诊断包括临床诊断和病理诊断, 临床诊断是皮肤黑色素瘤的初步排查, 病理诊断才是金标准。

皮肤黑色素瘤的病理诊断是将病变组织制作成病理切片, 由病理医生依据样本的病理特征人为诊断。典型的皮肤黑色素细胞痣和黑色素瘤病理样本如图 1-3 所示, 病理医生可根据 ABCD 法则^[6]和临床经验区分二者的不同: (a)样本边界

清晰，黑色素细胞形态一致，初步诊断为黑色素细胞痣；(b)样本边界不清晰，黑色素细胞胞浆明显，肿瘤区域呈现巢状，表皮基底层可见淋巴细胞浸润，初步诊断为黑色素瘤。

目前 HE 染色只能呈现如图 1-3 所示的信息，且现阶段尚无辅助工具为 HE 染色样本提供更详细的分析或定量化数据。为了进一步确诊，通常还需要对样本进行免疫组化染色，周期长，成本高。因此，亟需为皮肤黑色素瘤的诊断提供定量分析方案。




图 1-3 皮肤黑色素细胞痣和黑色素瘤病理样本

综上所述，皮肤黑色素瘤是一种恶性程度较高的皮肤恶性肿瘤，发病率和死亡率逐年提高。因此，现阶段亟需一种技术手段：根据皮肤黑色素瘤的 HE 染色样本定量化分析出组织中更多的信息，来为 HE 染色样本的诊断提供有效的理论和数据支持。这种技术手段能够避免免疫组化染色的繁琐过程，从而大幅提高皮肤黑色素瘤的诊断效率，具有十分重要的现实意义。

1.1.2 显微高光谱成像技术

成像光谱技术将目标探测技术和光谱成像技术相结合，在与观测目标不发生物理接触的情况下，远距离感知并描述目标的二维空间信息和一维光谱信息^[7]。根据光谱分辨率的大小，光谱成像技术可分为多光谱成像技术、高光谱成像技术和超光谱成像技术；相应地，光谱图像可分为多光谱图像、高光谱图像和超光谱图像^[8]。高光谱成像技术相比多光谱成像技术，光谱分辨率更高，目标的属性信息探测能力更强，是成像光谱学领域最具有研究价值、应用最广的技术之一^[9]。

高光谱成像技术最初应用在遥感成像上^[10]，也可以应用于农业^[11]、地学^[12]、环境监测^[13]等领域。相比传统的成像技术，高光谱成像技术不仅记录了物质的空间信息，还包含了物质的光谱信息。随着高光谱成像技术的日趋成熟，其在显微领域的应用也逐渐成为人们研究的热点^[14]。

近年来，随着显微技术的发展，人类对微观世界的认知有了很大的提升。显微技术利用光学系统原理，帮助人类研究肉眼看不到的微观物质形态结构及特性。目前，光学显微镜是显微技术应用的主要载体。

将高光谱成像技术和显微技术相结合，能够有效地采集微观物质的光谱曲线，为微观物质研究提供更丰富的图像信息。目前，显微高光谱成像技术在生物医学研究领域已得到广泛应用。Beach 等分析了在不同的压力下，眼睛呈现出来状态的高光谱图像数据，并计算出眼睛组织的含氧量^[15]。Dick 等基于显微高光谱成像技术，对皮肤组织进行了研究，研究结果表明，显微高光谱成像技术能够有效地检测皮肤组织中的异常情况^[16]。Akbari 等基于显微高光谱成像技术和支持向量机分类算法，有效地检测出病理切片样本中的癌细胞^[17]。李庆利等人设计并实现了推帚式的显微高光谱成像系统，使用该系统分别采集了正常和病变的血液样本，并通过分析处理，实现了病变样本的检测^[18]。

可见，随着显微技术和高光谱成像技术的发展，显微高光谱成像技术能够为微观物质提供一个新的视角去研究其特性，这对生物医学研究领域提供了一个新的契机。

1.2 选题的意义

近年来，皮肤黑色素瘤的发病率和死亡率逐年增长，早期确诊能够极大提高患者的治愈性。在现有的皮肤黑色素瘤诊断中，需要病理医生依据传统显微视场下的图像信息，结合自身经验进行诊断。由于传统显微视场下的图像信息只能呈现样本的二维空间信息，且 HE 染色呈现的组织形态特征不明显，因此，很难通过 HE 染色确诊皮肤黑色素瘤。在显微视场下，为皮肤黑色素瘤 HE 染色样本提供肿瘤的位置、大小、入侵深度等信息，能够提高病理诊断的准确率和效率。

针对这些问题,国内外研究者将越来越多的现代光学影像技术与图像处理技术相结合并应用到医学诊断中,例如通过高光谱荧光图像分析家禽皮肤肿瘤^[19]、通过核磁共振图像处理诊断乳腺肿块良性还是恶性^[20]、通过拉曼光谱对食道癌进行诊断^[21]。

具体到皮肤黑色素瘤的研究上,为了提高皮肤黑色素瘤早期诊断的准确性,皮肤镜学、数字皮肤镜学、高光谱成像技术等诊断工具已引入了皮肤黑色素瘤的早期诊断中^[22,23]。皮肤镜学和数字皮肤镜学是对皮肤黑色素瘤的宏观研究,而显微高光谱成像技术能够从微观角度研究皮肤黑色素瘤病理切片样本中的细胞特征,从而为病理诊断提供定量化分析。相比普通二维图像,高光谱图像包含了样本的光谱曲线信息,根据不同组织的光谱曲线特征,计算机能够自动识别样本中的肿瘤区域,同时能提供定量化的数据,这为皮肤黑色素瘤的诊断提供了重要的参考。

综上所述,病理诊断是皮肤黑色素瘤诊断必不可少的步骤,现阶段诊断方法仅仅是病理医生根据显微视场人为确定肿瘤区域,尚无定量化参考指标。现有高光谱成像技术的研究与应用表明,利用高光谱数据的丰富信息,结合图像处理算法,能够挖掘出图像中更多的隐藏内容。因此,本文将显微高光谱成像技术作为皮肤黑色素瘤病理诊断过程中的辅助工具,分别识别了皮肤颗粒层、恶性黑色素细胞、肿瘤区域。

首先,皮肤黑色素瘤手术切除大小判定十分重要,若切除不彻底,则容易导致癌细胞转移,极大影响了患者的预后,而入侵深度的测量能够为手术切除大小提供参考。为了准确地测量皮肤黑色素瘤的入侵深度,本文识别了皮肤颗粒层,为入侵深度的自动计算提供了起始边界。然后,在无明显病变组织的皮肤黑色素瘤样本中,恶性黑色素细胞是肿瘤扩散边界的判定依据,由于病理医生肉眼观察样本中的恶性黑色素细胞存在一定的误差,因此,对样本中恶性黑色素细胞的识别不仅能够辅助病理医生诊断,提高了诊断效率,也为入侵深度的计算提供了肿瘤边界。最后,由于皮肤组织的结构复杂多样,病变组织边界不清晰,这增加了

病理诊断判断肿瘤区域和边界的难度，因此，本文对样本中的肿瘤组织的进行了自动识别，为皮肤黑色素瘤的初步诊断提供了定量化参考数据。

1.3 国内外研究现状

1.3.1 皮肤黑色素瘤国内外研究现状

皮肤黑色素瘤治疗的各个阶段中，初步诊断是国内外学者现阶段研究的主要问题，通常是在宏观上对皮肤组织中的黑色素瘤进行自动检测、判定病灶区域大小。在国内，对皮肤黑色素瘤的研究主要基于皮肤镜、激光共聚焦等技术，重点研究图像处理算法对黑色素瘤的识别、特征提取等。王婷等利用激光共聚焦扫描显微镜图像，通过小波分析法分析黑色素瘤的纹理，并在小波分析的特征参数基础上，采用分类与回归树算法对图像进行分类，实验结果表明，该方法能够提高黑色素瘤早期诊断的准确率^[24]。胡言广基于皮肤镜图像，采用了图像融合、七点检测法、支持向量机分类算法取得了更准确的黑色素瘤分类效果，结果表明，提出的方法在黑色素瘤的诊断中具有重要意义^[25]。

在国外，Nagaoka 等通过研究黑色素瘤高光谱数据，提出了一种早期黑色素瘤筛选系统，并得出了基于黑色素瘤色素分子特性的黑色素瘤鉴别指标^[26]，该指标的实践样本不多，但在区别黑色素瘤与非黑色素瘤上比较成功。之后，他们通过对日本人病例的研究又提出接近临床专家的三步诊断法，实现了较高的诊断性能^[27]，通过进一步实验，对鉴别指标做出了改进^[28]。Zheludev 等提出了一种非侵入式方法描绘皮肤恶性雀斑痣和恶性雀斑痣样黑色素瘤，该方法是在手术切除前，分别采集病变区与正常组织的高光谱数据，提取两个区域像素的光谱特征，采用分类算法及扩散图技术揭示了光谱数据的内部结构^[29]。

由皮肤黑色素瘤国内外研究现状可知，研究者侧重于使用图像算法准确描绘皮肤表面的肿瘤区域，但无法准确判断皮肤黑色素瘤的病灶区组织形态和入侵深度。

1.3.2 显微高光谱成像技术国内外研究现状

国内外学者对高光谱成像技术做了大量研究,并结合图像处理研究出较多的物质识别、分类算法等^[30,31]。在近几年,学者将高光谱技术应用到医学领域,将其作为临床病理的诊断辅助工具^[32],并取得了一定的成果,结果显示,高光谱成像技术在医学疾病诊断领域中具有较大的发展前景^[33,34]。

目前,显微高光谱成像技术主要应用在算法研究和疾病诊断中。在国内,李庆利等提出了一种光谱与距离结合的皮肤上皮细胞分割算法,该算法在光谱角分类方法中加入距离特征,比 k-均值、模糊 c-均值等算法更有效^[35]。易伟松探讨了高光谱技术应用在微观层次的胃癌组织中的研究现状,表明高光谱成像技术能为胃癌的诊断、手术边缘确定、预后等过程提供理论指导及技术支持^[36]。可见,高光谱成像技术在微观层次研究中得到了实践。

在国外,Akbari 等基于猪的动脉静脉高光谱图像,利用高光谱图像分类算法成功区分出样本中的静脉和动脉,同时能够发现血管中是否存在异常^[37]。Zherdeva 等基于高光谱成像技术,提出了一种皮肤和肺部肿瘤可视化方法和诊断方法^[38]。Tsapras 等提出了一种高光谱检测系统,该系统集成了高光谱图像分类算法,能够检测发育不良痣与黑色素瘤在小鼠活体内的区别;同时,将正常组织与黑色素瘤组织光谱特性作为参考,提出了检测由发育不良痣形成黑色素瘤的动物模型,该系统的灵敏度较高,具有提高黑色素瘤的诊断效率的潜力^[39]。该研究是基于皮肤组织表面的研究,无法得到肿瘤组织的细胞形态。Chung 等利用高光谱成像技术,结合超像素光谱分类算法检测头部与颈部癌症,结果表明高光谱成像技术和该分类方法可以在癌症研究和管理中具有广泛的应用^[40]。Fei 等将高光谱技术用于肿瘤边缘估计,提出了高光谱图像数据的预处理和分类方法,该方法具有较高的头颈癌组织识别精度,可以看出高光谱成像技术对手术组织标本的肿瘤边缘评估具有巨大的潜力^[41]。

由皮肤黑色素瘤和显微高光谱成像技术的国内外研究表明,高光谱技术主要应用在皮肤黑色素瘤的宏观研究上,但宏观上无法为病理诊断提供肿瘤组织的细胞形态。同时,高光谱成像技术能在微观上为肿瘤组织提供更丰富的信息,例如

肿瘤中细胞的形态、入侵深度。因此，将显微高光谱成像技术应用在皮肤黑色素瘤病理诊断中，为病理诊断提供定量化依据具有极其现实的意义。

1.4 本文主要研究内容及结构安排

高光谱成像技术能够获取样本图像的空间信息和光谱信息，基于丰富的图像信息，较多的图像处理算法被提出，从而实现了该技术在各个领域中的研究价值。本文利用显微高光谱成像系统采集了皮肤黑色素瘤病理样本的图像数据，针对样本数据的特性，将其分为三类，分别研究了不同的显微高光谱图像处理算法对三类样本进行处理，结果显示，本文研究的方法能够识别样本中的肿瘤组织，并为皮肤黑色素瘤的诊断提供定量化分析。本文主要工作流程如图 1-4 所示。




图 1-4 论文研究流程图

本文主要研究内容如下：

第一章为绪论，首先介绍了皮肤黑色素瘤和显微高光谱成像技术的背景，然后介绍了本文的研究意义，最后回顾了皮肤黑色素瘤和显微高光谱成像技术的国内外研究现状，为显微高光谱成像技术在皮肤黑色素瘤识别中的应用提供了现实依据。

第二章首先介绍了显微高光谱成像系统的组成和性能指标,然后介绍了该系统的采集方法以及样本数据格式和数据校正方法。随后介绍了皮肤黑色素瘤样本的来源和制作方法,最后基于皮肤组织的多样性和显微视场的局限性的原因,对采集的皮肤黑色素瘤样本进行分类介绍。

第三章提出了显微高光谱图像识别方法。基于皮肤黑色素瘤样本的多样性,本章提出了显微高光谱图像的分割和分类算法,识别皮肤黑色素瘤样本中的不同组织。首先,为了计算皮肤黑色素瘤的入侵深度,本章提出了基于核最小噪声分离(KMNF)的分割方法识别皮肤颗粒层,并提出了基于特征光谱监督的最小二乘法支持向量机(CSS-LSSVM)分割方法识别恶性黑色素细胞。其次,为了快速识别样本中的肿瘤区域,本章采用了基于粒子群优化的极限学习机(PSO-ELM)分类方法识别并定量化样本中的肿瘤区域。最后,为了验证算法的有效性,介绍了真阳率、真阴率、假阳率、假阴率、准确率、敏感性、特异性的计算方式,为第四章皮肤黑色素瘤识别结果提供定量化计算依据。

第四章为皮肤黑色素瘤识别及定量化分析。本章对不同类型的皮肤黑色素瘤样本进行实验分析。首先展示了病理图像和基于 KMNF 的分割方法对皮肤颗粒层的分割结果,对比了基于主成分分析(PCA)、最小噪声分离(MNF)、核最小噪声分离(KMNF)的分割结果,结果表明,基于 KMNF 的分割方法对颗粒层的分割精度最高。其次展示了基于 CSS-LSSVM 的分割方法对恶性黑色素细胞的分割结果,并对比了四个样本的 SVM 和 CSS-LSSVM 分割结果,结果表明,CSS-LSSVM 具有较高的分割精度。然后展示了两个样本的 SVM 和 PSO-ELM 的皮肤黑色素瘤分类结果和耗时,结果表明,PSO-ELM 在能够识别出更多肿瘤组织的同时,极大缩短了分类时间。最后,根据皮肤颗粒层分割结果和恶性黑色素细胞分割结果,提出了皮肤黑色素瘤入侵深度的测量方法,并计算了皮肤黑色素瘤的入侵深度。

第五章为总结与展望。主要总结了本文工作,并对下一步的研究提出了展望。

图 1-5 给出了本文研究内容结构图。




图 1-5 论文研究内容结构图

第二章 显微高光谱成像系统及皮肤黑色素瘤样本

2.1 显微高光谱成像系统

显微高光谱成像系统结合了高光谱技术和显微成像技术，系统包括硬件和软件部分，成像质量较高。该系统实现了参数设置、图像预览、图像自动采集、图像基本处理等功能，本文使用的高光谱图像数据均通过该系统采集。

2.1.1 系统组成

本文中显微高光谱成像系统是基于李庆利^[42]等提出的显微高光谱医学成像机理，通过置换了精度更高的部分器件，从而具有更好的成像效果。该系统包括硬件和软件两个部分，硬件组成有：光学显微镜、声光可调谐滤光器(AOTF)、高灵敏度彩色电荷耦合器件(CCD)相机、高灵敏度灰度 CCD 相机、高精度三维载物台、环形光源、防振台、计算机组件(显示屏、主机)，软件为图像采集软件。系统原理如图 2-1 所示。




图 2-1 系统原理图

系统实物如图 2-2 所示，(1)为彩色 CCD、(2)为灰度 CCD、(3)为高精度三维载物台、(4)为光学显微镜、(5)为防振台、(6)为 AOTF 射频驱动器、(7)为图像采集控制器、(8)为工业计算机。显微高光谱成像系统安装方式为，防振台放置在

地面上，高 1 米左右，防振台材质精密、结构稳固，具有较好的防振效果，能够保证在图像采集过程中，样本处于几乎相对静止的状态。光学显微镜固定安装在防振台上。高精度三维载物台固定安装在光学显微镜的光源与物镜之间，用于放置样本。环形光源安置在显微镜光源与载物台之间，实现聚光、固定光强度等功能。高精度彩色 CCD、灰度 CCD 相机镜头部分均安装在光学显微镜上，通过串口与工业计算机相连接，利用串口与计算机进行数据交互。高精度三维载物台既可手动控制，也可编程控制，通过 USB 与工业计算机相连。声光可调谐滤波器(AOTF)通过串口与计算机连接。采集图像软件各个功能由编程语言 C++开发实现，安装在工业计算机上，该软件有可视化界面，具有良好的人机交互能力。




图 2-2 系统实物图

2.1.2 系统性能指标

系统的高精度三维载物台在三维方向上的移动有两种控制方式：移动手柄手动控制、程序设置参数自动控制。高精度三维载物台根据单步移动距离的大小分为多级调节模式，在这种模式下，可先粗调再微调，时间上更高效距离上更精准。手柄调节灵敏度低于 0.1s，程序调节灵敏度低于 0.01s。高精度三维载物台在 x、y、z 轴方向上的最高移动精度可达 0.1 μ m，移动速度可达 20mm/s。在实际样本采集中，移动手柄控制和程序设置参数自动控制两种方法均集成到图像采集软件中，可以根据不同样本的实验需求选择三维高精度载物台的移动控制方式。本文

样本均为单视场多光谱数据采集,因此,采集前,手动调节载物台左右位置选取目标视场,上下调节载物台的位置聚焦,在数据自动采集过程中保持载物台的位置不动。

系统采用的 AOTF 光谱分辨率可达 1nm,稳定性好,即使长时间工作也能保证波长的波动误差小于 0.01nm。根据生物切片样本在可见光范围内具有吸收光谱的特性,系统光源发出可见光,光源发生器采用卤素灯。结合系统组件 AOTF 硬件特性,选取可见光到近红外线区域的光谱范围,因此,本文中系统可选择的光谱范围为 373-809nm。

系统包含彩色 CCD 和灰度 CCD,其参数均可设置。由于彩色 CCD 与灰度 CCD 的型号不同,因此视场的成像大小不能完全一样。彩色 CCD 采集视场的彩色图片,用于还原样本在显微镜下最初呈现的状态,作为高光谱图像处理结果的对比图像。彩色 CCD 只采集单张视场 RGB 图像,因此,采集参数可选取默认值。灰度 CCD 用于采集该视场的高光谱图像数据,曝光时间可调节范围为 0.1ms-65s,采集暗电流平均低于 0.7e/pixel,在较高的采集速度下,可以降低采集瞬间间隔里光照环境对成像质量的影响。因此,在多波段高光谱数据采集,系统灰度 CCD 能够达到较高的采集速率。同时,可根据实验需要设置灰度 CCD 成像数据像素点的灰度级为 8bit 或 16bit,保证了不同样本在不同的光照条件下的图像均具有较高的质量。本文中使用的样本像素点的灰度级为 16bit。

2.2 数据采集与光谱校正方法

2.2.1 数据采集及数据格式

高光谱数据采集,单波段图像数据与普通二维图像数据形式一致,只包含空间信息。采集多波段光谱图像数据时,对同一个视场,在不同的波段下均采集一张单波段图像,并记录波长信息,将多个单波段图像数据与波长信息共同保存为高光谱图像数据包。系统的图像采集软件为每个视场生成图像数据包.raw 文件和数据文件存储方式描述.hdr 文件。本文使用的数据均为多波段光谱图像数据。

显微高光谱成像系统多波段图像数据采集流程如图 2-3 所示:




图 2-3 数据采集流程图

多波段图像采集时，首先将样本固定在载物台上，调节好合适光源，一次连续采集过程中光源强度保持不变，选择合适的放大倍数，打开图像采集软件。然后切换到显微镜视场通道，手动调节载物台找到目标视场；切换到彩色 CCD 通道，手动上下调节载物台到图像聚焦的位置，通过图像采集软件采集彩色图像数据；切换到灰度 CCD 通道，在预览的时候，手动上下调节载物台使目标区域聚焦后，设置图像采集软件采集参数(增益、曝光时间、采集波段数)，点击采集按钮自动采集。图像采集软件自动为每个视场生成.raw 无损压缩文件格式的数据包和.hdr 数据文件存储方式描述文件。最后采集完该样本的目标区域，移动载物台到样本的空白区域，保持目标区域相同的采集环境和参数，采集空白样本多波段图像数据。

在系统图像采集软件生成的文件中，.raw 文件的图像数据按波段顺序存储 (BSQ)，即将 K 张单波段图像数据连续存储，从低波段到高波段，每个波段按行到列的顺序存储，在 .raw 文件中像元顺序为：

$$P_1(1,1), \dots, P_1(1,m), P_2(2,1), \dots, P_2(2,m), \dots, P_K(n,1), \dots, P_K(n,m)$$

.raw 文件存储方式如图 2-4 所示：

高光谱数据.raw文件	第1波段	第2波段		第K-1波段	第K波段
其中第i波段	Pixel (1, 1)	Pixel (1, 2)		Pixel (1, m-1)	Pixel (1, m)
	Pixel (2, 1)	Pixel (2, 2)		Pixel (2, m-1)	Pixel (2, m)
					
	Pixel (n-1, 1)	Pixel (n-1, 2)		Pixel (n-1, m-1)	Pixel (n-1, m)
	Pixel (n, 1)	Pixel (n, 2)		Pixel (n, m-1)	Pixel (n, m)

图 2-4 .raw 文件存储方式

.hdr 文件中列出采集时间、每行采样点数(samples)、行数(lines)、波段数(bands)等信息。.hdr 文件内容如图 2-5 所示,可知该样本的单行采样点数(samples)为 1800, 行数(lines)为 1300, 波段数(bands)为 60, 在后续图像处理中主要用到这三个参数。

说明头文件(.hdr)	<pre>ENVI description = { Create New File Result [Sun Jul 16 14:37:44 2017]} samples = 1800 lines = 1300 bands = 60 header offset = 0 file type = ENVI Standard data type = 2 interleave = bsq sensor type = Unknown byte order = 0 x start = 0 y start = 0 wavelength units = Unknown</pre>
-------------	--

图 2-5 .hdr 文件内容

系统采用上述多光谱图像数据 BSQ 存储方式的优势是:能根据.hdr 文件中的描述信息简单快速地将每个波段对应的二维图像信息提取出来,从而快速定位到某波段的某个像素,方便后续针对波段做图像处理。在此基础上,利用 MATLAB 快速处理矩阵的特性,结合 BSQ 的存储方式,能方便快捷的将.raw 图像数据分解为 $n \times m \times K$ 的数据立方,其中 K 为采集波段总数, $n \times m$ 为单波段图像大小。

高光谱数据如图 2-6 所示, 可知, 显微高光谱成像系统采集的高光谱数据不仅包含了二维空间信息, 还包含了单一像素的光谱曲线特征。




图 2-6 高光谱数据立方图

2.2.2 高光谱图像样本校正

显微高光谱成像系统采集图像数据时, 光照强度、CCD 电噪声等外界条件变化对成像的数据质量有一定的影响。由于生物样本对光谱的吸收特性较小, 这导致采集的光谱曲线与原始光路中的曲线相似, 为了去除外界条件对组织光谱曲线的影响, 只保留组织自身的光谱曲线特性, 在数据处理前应首先对其进行光谱校正。

在之前的研究中, 显微高光谱成像系统的数据样本校正方法包括: 光的透光率^[43]、Lambert-Beer 定律^[44]、空间维度与光谱维度联合校正^[45]。以上校正技术原理一致, 是根据样本对光谱的吸收和反射率进行校正。空间维度与光谱维度联合校正方法与透射率和 Lambert-Beer 定律的区别在于, 通过计算光谱维度校正系数和空间维度校正系数, 联合两种校正系数, 使校正后的光谱在空间维度上得到了延伸, 但是对光谱反应物质的特性没有效果上的增强。

Lambert-Beer 定律表示了物质对单一光的吸收强度与其浓度和厚度之间的关系。假设物质的吸光度为 A 、透光率为 T , 则 Lambert-Beer 定律的数学表达式为:

$$A = -\log T \quad (2-1)$$

假设物质的平行单色入射光强度为 I_0 , 透射光强度为 I , 则透光率 T 为:

$$T = \frac{I_0}{I} \quad (2-2)$$

本文实验数据(包括目标样本数据和空白样本数据)通过 HE 染色样本采集而成。在目标样本数据采集过程中,平行单色入射光依次通过压片、生物组织、透明玻璃载玻片。空白样本数据采集过程中,平行单色入射光依次通过压片、透明玻璃载玻片,光路效果如图 2-7 所示。




图 2-7 入射光光路效果图

因此,透光率为:

$$T(n, m; \lambda) = \frac{D(n, m; \lambda) - I(n, m; \lambda)}{B(n, m; \lambda) - I(n, m; \lambda)} \quad (2-3)$$

则吸光度 A 表达式为:

$$A(n, m; \lambda) = \log \frac{B(n, m; \lambda) - I(n, m; \lambda)}{D(n, m; \lambda) - I(n, m; \lambda)} \quad (2-4)$$

其中 $D(n, m; \lambda)$ 为目标样本在第 λ 波段中 n 行 m 列的像素值, $B(n, m; \lambda)$ 为空白样本在第 λ 波段中 n 行 m 列的像素值, $I(n, m; \lambda)$ 为该像素点在光源关闭和再次打开之间物镜获取的图像噪声。因为系统硬件的参数稳定,所以每个像素点位置的图像噪声一致。通过提取数据样本吸光强度的方法提取样本组织实际的高光谱特性曲线,能够消除系统设备噪声、样本染料不均等因素的影响。

选取某一样本数据,对样本进行光谱校正,实验结果对比如图 2-8 所示。图 2-8 为皮肤黑色素瘤样本在 200X 放大倍数下的视场,该视场下主要包括肿瘤区

域和正常纤维组织，分别选取了细胞核、肿瘤病变组织、空白、纤维组织四个区域的光谱曲线作对比。




图 2-8 高光谱图像样本校正结果对比

图 2-8 中，(a)为波长为 658nm 的单波段高光谱图像视场，(b)为(a)中红色部分区域的放大，其中红色为恶性黑色素细胞的细胞核，蓝色为病变区域组织，深红色为无皮肤组织覆盖的载玻片空白区域，绿色为正常的纤维组织。(c)为校正前四个区域对应的光谱曲线，由曲线可知每类组织对应的光谱曲线特征类似，随着波长的增加，在相同的波长处呈现明显的波峰和波谷，仅在光谱值范围上有一定的差异。将高光谱数据与空白数据代入式(2-3)可得到校正后的高光谱数据，图 2-8 中(d)为(c)中区域校正后的光谱曲线，由校正后的光谱曲线可知，不同组织的光谱曲线特征差异较大，更能反应各自的生化特征。

2.3 皮肤黑色素瘤样本制备和类型

2.3.1 皮肤黑色素瘤样本制备

常规病理制片在病理切片技术中极其重要，是所有病理技术的基础，制作过程主要包括的步骤有：组织样本取材、固定、脱水、浸蜡、包埋、切片、烤片、染色、封片^[46]。针对皮肤疾病的样本特性，皮肤黑色素瘤 HE 染色病理切片的制作步骤和注意事项如下：

（1）组织标本取材

由于各种疾病的发生、发展具有其固定的规律，因此根据疾病的病理特征去取材，才能获得想要的病理信息。对于皮肤黑色素瘤组织的取材，首先应找到原发损害区域，其次对该区域切取足够的深度和宽度。对于皮肤黑色素瘤取材通常包括表皮、真皮和皮下组织三层，便于初步判断入侵深度。均由手术医生采用标本穿刺针取材或者手术切除组织取材。

（2）组织标本固定

组织离开生物体后会很快失去其生物活性，为了保证离体组织中的细胞特性与生活状态中的形态学结构一致，手术切下的标本应立即放入固定剂中固定。固定剂能阻止分解酶的继续作用，防止组织自溶。固定剂通常采用含量为 10% 的中性甲醛，固定液量与样本大小比高于 5:1。组织样本大小不同，固定时间长度也不同，大样本通常需要 12-24h，小样本通常需要 2-4h，固定过程中环境温度保持在 25℃。

（3）组织标本水洗、脱水、透明

经过固定后的组织表面会残留甲醛，则需要经过水洗去除组织表面的甲醛。为了有机溶剂更好地渗入组织样本，需要对组织样本脱水。因为组织标本中含有的水分与石蜡包埋材料不相溶，因此脱水是否彻底对后续透明、浸蜡等步骤影响很大。脱水通常采用不同浓度的乙醇，从低浓度到高浓度，低浓度乙醇穿透力强，比高浓度乙醇更容易渗入组织内部，因此脱水时间可稍长；高浓度乙醇脱去组织标本在浓度乙醇脱水后残留的水分，脱水时间较短。

透明的目的是使脱水后的组织能与石蜡相溶。目前，使用最广泛的透明剂是二甲苯，常温下，透明时间不宜过长，组织样本呈琥珀状或者棕黄色即可。

(4) 组织标本浸蜡、包埋

浸蜡是将融化的石蜡内浸渍到组织标本中。浸蜡需要掌握适当的时间，时间过长会导致组织过硬，时间过短石蜡没有完全渗入组织，组织过软。浸蜡时间过长或过短都会使切片困难。包埋是石蜡凝固完全包住组织的过程，需要掌握石蜡的熔点，根据季节不同，熔点通常在 54-58℃ 之间。包埋时需要注意切面平坦，使切片时样本分布均匀。

(5) 切片

切片前先检查切片机是否正常工作，调整切片机的切片厚度调节器为 4-5um。切片时首先切除组织外的余蜡部分，保持切面平坦。切下组织放入 50℃ 左右的温水中，待切片在温水中展开，则捞起展开的切片放置在载玻片上，并放入温度为 60-65℃ 的恒温烤箱中烤 20-30min。

(6) HE 染色

染色前需要先对切片脱蜡，通常采用二甲苯 I、II 分别脱蜡 20min，根据季节，脱蜡时间长短不一，尽量保证充足的脱蜡时间，脱蜡不完全会影响染色效果。样本脱蜡后依次经过不同浓度的乙醇去除二甲苯，然后经过水洗，最后进行染色。HE 染色即苏木精-伊红染色，是石蜡切片的常用染色，苏木精染液呈碱性，使皮肤组织中细胞核、颗粒、基底层、小汗腺及其导管、棘层呈蓝色；伊红为酸性染料，使皮肤组织中角质层、血管、胶原纤维、大汗腺及其导管呈红色。

2.3.2 皮肤黑色素瘤样本类型

皮肤组织结构复杂，皮肤黑色素瘤样本类型繁多。然而，在显微视场下，无法完全包含皮肤组织所有结构，因此，本节针对不同的研究目的将皮肤黑色素瘤样本分为三类，分别介绍了正常皮肤组织和三类皮肤黑色素瘤样本的特征。

图 2-9 为显微视场下正常皮肤组织结构，(1)为表皮层，该样本无明显角质层，(2)为真皮层，箭头(3)为皮下组织，其中左上角的蓝色箭头指向样本空白区域，绿色箭头指向真皮层淋巴细胞，浅绿色箭头指向真皮层纤维，黄色箭头指向毛囊，

橙色箭头指向皮下组织脂肪小叶，紫色箭头指向皮下组织肌肉。由图 2-9 可知，正常皮肤组织的各层组织结构不相同，每种组织都呈现其正常形态，无病变现象。




图 2-9 正常皮肤组织显微视场

本文使用的皮肤黑色素瘤样本主要为浅表扩散性黑色素瘤，病灶多发于表皮层和真皮层，病灶边界明显或者不明显，恶性黑色素细胞存在于病变组织中。恶性黑色素细胞细胞核较大，存在明显的胞浆，病灶区组织炎症反应明显。由于显微视场的局限性，低倍镜下皮肤组织各层包括全面，但细胞组织细节不能表达，高倍镜下细胞组织清晰，但无法包括皮肤各层组织。通常为了不同的研究目的选择不同的样本采集视场和采集放大倍数。

因此，根据采集的样本视场特性以及研究内容，本文研究的样本分为三种：100X 下主要包含表皮层和恶性黑色素细胞(用于测量皮肤黑色素瘤的入侵深度)、200X 下主要包含恶性黑色素细胞(用于恶性黑色素细胞分割)、100X 下主要包含正常组织和肿瘤组织(用于皮肤黑色素瘤病变区域识别)。

(1) 样本类型 1：100X 下主要包含表皮层和恶性黑色素细胞

样本类型 1 的主要特点为包含表皮层全层和真皮层部分，样本如图 2-10 所示。图 2-10 展示了两个样本类型 1 的样本，样本的彩色图像视场分别为(a)和(c)，单波段高光谱图像视场分别为(b)和(d)。(a)和(c)中(1)为表皮层全层，(2)为角质层，(3)为颗粒层。图中，橙色箭头指向样本空白区域，红色箭头指向恶性黑色素细

胞，绿色箭头指向表皮层的正常组织，黄色箭头指向真皮层纤维组织。样本 1 中主要为恶性黑色素细胞无规律分布在真皮层，样本 2 中恶性黑色素细胞分布在表皮基底层，恶性黑色素细胞核仁明显，胞浆明显。




图 2-10 皮肤黑色素瘤样本类型 1

(2) 样本类型 2：200X 下主要包含恶性黑色素细胞

由于放大倍数的提升，样本类型 2 中主要包含病灶区恶性黑色素细胞，相比样本类型 1 和类型 3，样本类型 2 的样本中恶性黑色素细胞形态更清楚，有利于进一步研究恶性黑色素细胞的特性，因此，该类样本主要用于恶性黑色素细胞的分割。图 2-11 展示了样本类型 2 的两个样本，与图 2-10 类似，(a)与(c)为样本的彩色视场，(b)与(d)分别为其对应的单波段高光谱图像视场。样本中黄色箭头指向皮肤纤维组织，橙色箭头指向样本空白区域，红色箭头指向恶性黑色素细胞核或胞浆。样本 1 中绿色箭头指向视场中央的血管，可见恶性黑色素细胞分布在血管周围，并开始入侵血管。样本 2 中绿色箭头指向表皮层的正常组织，该视场恶性黑色素细胞聚集成巢，胞浆明显。




图 2-11 皮肤黑色素瘤样本类型 2

(3) 样本类型 3: 100X 下主要包含正常组织和肿瘤组织

样本类型 3 更关注肿瘤病灶区, 包含病灶区与正常皮肤组织, 主要用于肿瘤区域的识别。图 2-12 展示了两个含有明显病变组织的样本类型 3, 与图 2-10 类似, (a)与(c)为样本的彩色视场, (b)与(d)分别为其对应的单波段高光谱图像视场。其中, 橙色箭头指向空白区域, 红色箭头指向皮肤黑色素瘤肿瘤区域, 绿色箭头指向皮肤表皮层, 黄色箭头指向正常皮肤组织。由图 2-12 可知, 皮肤黑色素瘤样本类型 3 中病灶区组织病变明显, 病变组织中含有较多的恶性黑色素细胞。样本 1 中肿瘤区域边界不明显, 病灶区位于表皮基底层, 恶性黑色素细胞密集分布在病灶区, 胞浆明显。样本 2 中, 恶性黑色素细胞在表皮层聚集成巢, 细胞核仁明显, 胞浆明显, 细胞核可见有丝分裂, 真皮层存在明显的炎症反应。




图 2-12 皮肤黑色素瘤样本类型 3

由皮肤黑色素瘤的三类样本分析可知，不同的皮肤黑色素瘤样本特点不一。因此，针对不同的研究目的，将样本分类对样本的针对性研究具有重要的意义。

2.4 本章小结

本章首先介绍了显微高光谱成像系统的设计和组成，分别给出了系统组成的原理图和实物图，并列举出主要设备的参数。系统参数表明，该系统具有成像质量高、采集速度快等特点。其次，根据显微高光谱成像系统的特性，本章给出了实验数据采集方法。同时，本章讨论了高光谱数据的光谱校正方法，选取计算透光率的方式对样本进行光谱校正，并展示了光谱校正前后的对比结果，结果表明，光谱校正后的数据更能反应各组织的真实光谱特征。最后，本章介绍了皮肤黑色素瘤样本的制作方法，并结合实际皮肤黑色素瘤病理样本的特点，将皮肤黑色素瘤样本分为三类，分别详细说明了每类样本的特征。

第三章 皮肤黑色素瘤显微高光谱图像识别方法

常见的显微高光谱图像处理方法有图像降维、分割、分类等，学者通常根据不同的研究目的选取不同的处理方法。本章主要研究皮肤黑色素瘤的显微高光谱识别分析算法，提出了两种分割算法和一种分类算法。首先，本章提出基于核最小噪声分离(KMNF)的分割方法，用于分割皮肤颗粒层，为皮肤黑色素瘤入侵深度的计算提供准确的起始边界。其次，本章提出了基于特征光谱监督的最小二乘支持向量机(CSS-LSSVM)的分割方法，用于分割样本中的恶性黑色素细胞，为皮肤黑色素瘤入侵深度的计算提供肿瘤边界，也为病理医生的诊断提供了一种自动标注恶性黑色素细胞的方法。此外，本章采用了基于粒子群优化的极限学习机(PSO-ELM)分类方法，用于识别样本中的肿瘤组织及定量化分析。最后，通过量化的评估方法对所提出的算法的有效性进行评估。

3.1 显微高光谱图像分割方法

3.1.1 基于 KMNF 的分割方法

病理图像的分析研究中，由于 RGB 图像信息的限制，很难分割出图像中相似度极高的不同组织。相比 RGB 图像，显微高光谱图像包含多个不同波长的单波段二维图像信息，因此，图像的空间信息更丰富。

本小节的研究目标是实现皮肤颗粒层的分割。从皮肤组织学角度而言，皮肤颗粒层位于皮肤角质层和有棘层之间，在 HE 染色的病理图像中，颗粒层的特征不明显，因此很难分割。然而，在显微高光谱图像中，颗粒层的光谱曲线特征与其它组织不同，因此，对高光谱图像进行特征提取能够有效地分离出颗粒层的主要形态。

首先，本小节分析和对比了主成分分析(PCA)、最小噪声分离(MNF)、核最小噪声分离(KMNF)方法，并选取了 KMNF 作为本文的特征提取算法。

其次，在特征提取的基础上，采用固定的形态学算子去提取图像中相应的形状，从而实现目标形态的提取。

最后,研究了传统的图像边缘检测方法和水平集分割方法,选择了水平集分割方法来获得目标形态的轮廓。

本小节的研究内容结构如图 3-1 所示。




图 3-1 本节研究内容结构图

3.1.1.1 高光谱图像特征提取

在多波段高光谱数据采集,为了获得样本更丰富的光谱特征信息,通常采集几十甚至几百波段的数据。因此,多波段高光谱图像数据不仅包含普通图像没有的光谱特性,还具有更丰富的图像空间信息。显微高光谱成像系统可选择的波段数范围为 1-200,采集的波段数越多,样本的图像信息越丰富,但数据量也越大。

为了保证样本图像数据具有足够的光谱特征信息,同时降低数据量,本文使用的数据包含 60 个波段信息。显微高光谱图像数据中,同一视场相邻波段的空间信息差异较小,因此数据存在冗余,而单一波段的空间信息较少,不能满足复杂的图像研究。因此,为了充分利用高光谱数据中的空间信息,可首先对数据进行特征提取,将图像的大部分特征集中在少数波段中。

常用的高光谱图像特征提取方法有主成分分析(PCA)和最小噪声分离(MNF)。

1、主成分分析(PCA)

主成分分析(PCA)^[47]的基本思想是:通过线性变换,将 T 维数据映射到 L 维的降维操作,使 $L < T$ 。经过 PCA 降维操作后,前几个波段的信息量就能代表整个数据空间的主要特征信息,可选取前几个波段的数据进行后续处理。PCA 的主要功能是在保证数据特征的同时减少了数据量。对大小为 $n \times m \times K$ 的高光谱数

据, 首先, 将数据变为 K 维数据空间 $X = \{x_1, x_2, \dots, x_K\}$, 每一个维度代表第 λ 波段的图像数据, 即数据矩阵为:

$$X = \begin{bmatrix} x_1(1,1) & \cdots & x_1(n,m) \\ \vdots & \ddots & \vdots \\ x_K(1,1) & \cdots & x_K(n,m) \end{bmatrix} \quad (3-1)$$

PCA 的实现过程如下:

(1) 计算每个特征的均值 μ_i , 其中 $i \in [1, K]$, 即:

$$\mu_i = \frac{1}{K} \sum_{j=1}^K X_j(i) \quad (3-2)$$

则均值矢量:

$$\mu' = \{\mu_1, \mu_2, \dots, \mu_K\} \quad (3-3)$$

(2) 计算特征的协方差矩阵 Σ , $N = n \times m$ 。

$$\Sigma = \frac{1}{N} \sum_{i=1}^N (x_i - \mu')(x_i - \mu')^T \quad (3-4)$$

(3) 求协方差矩阵 Σ 的特征值 α 和特征向量 β , α 和 β 根据特征向量计算公式(3-5)计算。

$$(\alpha X - \Sigma)\beta = 0 \quad (3-5)$$

因为变换后的特征向量不相关, 因此 Σ 满足:

$$\Sigma = \begin{bmatrix} \alpha_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \alpha_K \end{bmatrix} \quad (3-6)$$

由于 PCA 变换后图像信息量按照从大到小排列, 则 Σ 特征值满足: $\alpha_1 > \alpha_2 > \dots > \alpha_K$ 。由于特征值 α_i 均对应一组特征向量 β_i , 则转换矩阵为 $Y = [\beta_1, \beta_2, \dots, \beta_K]$, 且满足 $X = Y^T Y = Y Y^T$ 。

(4) 计算变换后的高光谱数据。PCA 变换后的高光谱数据为:

$$D = Y^T X \quad (3-7)$$

2、最小噪声分离(MNF)

最小噪声分离(MNF)^[48]由 Green 等人提出, 最早用在遥感领域中实现图像降维和噪声分离。Sasaki 等人在研究人体皮肤受伤的高光谱数据样本中, 将 MNF

作为光谱角(SAM)处理前的降噪方法^[49]。MNF 是对主成分分析的改进，通过两次 PCA 达到更优的特征提取、分离噪声的效果。原理主要分为以下两步：

第一步，通过滤波器对图像数据进行滤波得到噪声的协方差矩阵，使噪声与数据信息分离，并与波段无关。给定噪声协方差矩阵 C_n ，则其对角化矩阵 D_n 可表示为：

$$D_n = U^T C_n U \quad (3-8)$$

设变换矩阵为 T ，归一化单位矩阵为 I ，则

$$I = T^T C_n T \quad (3-9)$$

$$T = U D_n^{-1/2} \quad (3-10)$$

第二步，通过得到的转换矩阵，对原数据协方差矩阵进行变换，即对得到的噪声数据进行标准的主成分变换。设原数据矩阵协方差为 C_D ，则变换后的矩阵 C_{TD} 为：

$$C_{TD} = T^T C_D T \quad (3-11)$$

最后将变换结果对角化可得：

$$D_{TD} = V^T C_{TD} V \quad (3-12)$$

D_{TD} 为 C_{TD} 按照特征向量降序排列的对角矩阵， V 为特征向量正交矩阵，由变换矩阵 T 和特征矩阵 V 可得最小噪声分离的变换矩阵：

$$T_{MNF} = TV \quad (3-13)$$

经过 MNF 变换后的图像数据中，前几个维度包含了图像数据大量的特征值以及较小的噪声，随着维度的增加，噪声越来越大且特征值越来越小。

3、核最小噪声分离(KMNF)

KMNF 是基于 MNF 的改进算法，在线性变换空间中引入核函数，使样本对空间的映射为非线性。设原始数据 $D(x)$ 的协方差矩阵为信号分量协方差矩阵 C_s 与噪声分量协方差矩阵为 C_n 的和，则定义噪声分数 NF_d 为：

$$NF_d = \frac{L^T C_n L}{L^T C L} \quad (3-14)$$

信噪比 SNR 为：

$$SNR = \frac{L^T C_s L}{L^T C_n L} \quad (3-15)$$

经过线性化计算，则 MNF 最大化式为：

$$\frac{1}{NF_d} = \frac{L^T CL}{L^T C_n L} = \frac{L^T P^T PL}{L^T P_n^T P_n L} \quad (3-16)$$

令 $L = \mathcal{L}^T \xi$ ，代入式(3-16)得到 MNF 的对偶模式：

$$\frac{1}{NF_d} = \frac{\mathcal{L}^T \xi \xi^T \xi \xi^T \mathcal{L}}{\mathcal{L}^T \xi \xi_n^T \xi_n \xi^T \mathcal{L}} \quad (3-17)$$

设 ξ_n 的映射为 $\mathcal{R}_n$ ，则 KMNF 的最大化式为：

$$\frac{1}{NF_d} = \frac{\mathcal{L}^T \mathcal{R} \mathcal{R}^T \mathcal{R} \mathcal{R}^T \mathcal{L}}{\mathcal{L}^T \mathcal{R} \mathcal{R}_n^T \mathcal{R}_n \mathcal{R}^T \mathcal{L}} = \frac{\mathcal{L}^T \mathbb{R}^2 \mathcal{L}}{\mathcal{L}^T \mathbb{R}_n \mathbb{R}^2 \mathcal{L}} \quad (3-18)$$

其中 $\mathcal{R}_n$ 为 $\Psi \times \lambda$ 的二维矩阵。在最小噪声分离变换的基础上增加的核函数 $\mathbb{R}$ ，可以完成原数据空间到特征空间的映射，计算简单，容易实现。

可见，相比 PCA，MNF 不仅提取了图像特征，还分离了图像噪声，降低了噪声对后续处理的影响。KMNF 是在 MNF 基础上引入核变换，将线性变换的 MNF 变为非线性变换，在原数据空间上实现了核函数计算。相比 MNF，KMNF 保留了光谱数据的非线性特征。因此，本文选择 KMNF 作为高光谱图像特征提取方法。

3.1.1.2 数学形态学滤波

皮肤黑色素瘤样本中，颗粒层在高光谱图像特征提取图像中呈现黑色条带状，因此，可通过形态学滤波提取颗粒层的主要形态。

数学形态学滤波是一种常见的图像处理方法，通过固定的形态学算子去提取图像中相应的形状，从而实现目标形态的提取。常见的数学形态学处理方法有膨胀、腐蚀、开运算与闭运算。已知显微高光谱数据 $D(i, j; \lambda)$ ($i \in n, j \in m$)，设形态模板为 $N \times M$ 的像素矩阵 $b(x, y)$ ($x \in N, y \in M$)，由于形态模板小于图像大小，因此 N 与 M 满足 $N < n, M < m$ 。

(1) 膨胀

膨胀运算表达式为：

$$D(i, j; \lambda) \oplus b(i, j) = \max(D(i-x, j-y; \lambda) + b(x, y)) \quad (3-19)$$

(2) 腐蚀

腐蚀运算表达式为：

$$D(i, j; \lambda) \ominus b(i, j) = \max(D(i+x, j+y; \lambda) - b(x, y)) \quad (3-20)$$

(3) 开运算

其中 $\circ$ 为开运算符，即先做腐蚀运算再做膨胀运算。

$$D(i, j; \lambda) \circ b(i, j) = [D(i, j; \lambda) \ominus b(i, j)] \oplus b(i, j) \quad (3-21)$$

(4) 闭运算

$$D(i, j; \lambda) \bullet b(i, j) = [D(i, j; \lambda) \oplus b(i, j)] \ominus b(i, j) \quad (3-22)$$

符号 $\bullet$ 为闭运算符，与开运算相反，闭运算符先做膨胀运算再做腐蚀运算。

常规的形态学算子为 $N \times N$ 的正方形滤波器，其中 $N=3,5,7\cdots$ 。本节中，为了更好的适应颗粒层的形状，设计了趋于菱形的多尺寸滤波算子，滤波算子尺寸如图 3-2 所示。




图 3-2 形态学滤波算子

不同尺寸的滤波算子滤波效果不同，滤波算子尺寸越大滤波效果越好，但图像边缘越模糊；滤波算子尺寸越小滤波效果越差，但图像边缘越清晰。针对样本中被提取目标形态的特性，合理选择开闭运算，并混合选择图 3-2 中的三种滤波算子尺寸，可达到更好的形态提取结果。

3.1.1.3 基于水平集分割的图像边缘检测

皮肤颗粒层通常作为皮肤黑色素瘤入侵深度测量的起始边界，因此，在获取到皮肤颗粒层的形态后，需要进一步提取颗粒层的边缘。

图像边缘是图像灰度值变化剧烈的地方。图像边缘信息反映了图像物质间的边界信息和图像的轮廓，是图像的基本信息。图像边缘检测能过滤掉大量的图像信息，只保留重要的边缘结构信息。

常用的图像边缘检测算子有 Sobel 算子、Roberts 算子、Laplacian 算子和 Canny 算子。以上四种算子能够提取大多数图像轮廓，其中 Canny 算子效果最好，能够提取更连续的图像轮廓。然而，经过形态学滤波后的图像，Canny 算子也不能提取连续的图像轮廓，因此，需要研究效果更好的图像边缘提取方法。

对于某些图像，传统的图像边缘检测算子无法提取连续的轮廓，因此，本节研究了基于水平集分割的图像轮廓提取方法。近年来，在图像分割方法中，活动轮廓模型是研究的热点^[50]。活动轮廓模型的基本思想是：使用连续的曲线来表达目标区域的轮廓，同时定义能量函数，该能量函数的自变量包含连续曲线，从而将分割过程转化为了求解能量函数最小化的过程。

为了解决活动轮廓模型中的参数形式描述曲线演化的局限性，学者提出了水平集分割算法。水平集算法是在 1988 年由 Osher 等人首次提出的算法，是用来对界面追踪和形状建模的算法^[51,52]。该方法的出现极大地促进了几何活动轮廓模型的发展。近些年来，水平集算法被广泛的应用于图像处理。该算法的基本思想是将目标边界作为零水平集，嵌入到更高一维曲面的水平集函数中去，高维闭合曲线的演化就转化为了水平集函数的演化^[53]。简而言之就是起到高维函数的降维作用，从而简化模型和计算。

对图像进行分割的演化曲线，一般是简单的光滑封闭的曲线，其参数表达形式如下：

$$C(p, t) = (x(p, t), y(p, t)) \quad (3-23)$$

其中， p 为任意的参数变量， t 为时间。曲线的偏微分方程如式(3-24)所示：

$$\frac{\partial C(p, t)}{\partial t} = V(p, t) \quad (3-24)$$

其中， $V(p, t)$ 是速度函数，表示曲线的变化速度，可以分为切向速度和法向速度。根据力学和几何学知识，可以知道只有法向速度会影响曲线的属性，因此只保留法向速度，得到：

$$\frac{\partial C(p, t)}{\partial t} = V(p, t) \cdot N \quad (3-25)$$

其中 N 是法向速度分量。

假设二维平面上的曲线为 $y = f(x)$ ，也可以表示为 $y - f(x) = 0$ 。此时，设定：

$$\phi(x, y) = y - f(x) = 0 \quad (3-26)$$

将式(3-23)中的闭合曲线引入到水平集函数 $\phi(x, y)$ 中，得到：

$$\phi(C(t), t) = 0 \quad (3-27)$$

对上述方程求解全微分方程得到：

$$\nabla \phi \frac{\partial C}{\partial t} + \frac{\partial \phi}{\partial t} = 0 \quad (3-28)$$

其中， $\nabla \phi$ 为函数 ϕ 的梯度。

结合式(3-25)，根据 $N = -\frac{\nabla \phi}{|\nabla \phi|}$ 得到：

$$\frac{\partial \phi}{\partial t} = V \cdot \nabla \phi \quad (3-29)$$

扩展到整个水平集平面，可以得到水平集平面的速度函数为 F ，因此可以得到：

$$\frac{\partial \phi}{\partial t} = F \cdot \nabla \phi \quad (3-30)$$

将水平集分割应用到图像分割过程中，一般将式(3-30)转换为能量函数形式，如下：

$$\frac{\partial \phi}{\partial t} = \frac{\partial E}{\partial t} \quad (3-31)$$

其中， E 为能量函数。

典型的水平集分割模型有 Mumford-Shad 模型，是一种基于能量函数最小化思想的图像分割模型^[54]。其最小化能量函数的过程为：

$$\begin{aligned} F(c_1, c_2, C) = & \mu \cdot \text{Length}(C) + \nu \cdot \text{Area}(\text{inside}(C)) \\ & + \lambda_1 \int_{\text{inside}(C)} |u_0(x, y) - c_1|^2 dx dy + \\ & + \lambda_2 \int_{\text{inside}(C)} |u_0(x, y) - c_2|^2 dx dy \end{aligned} \quad (3-32)$$

其中, $u_0(x, y)$ 为给定的图像, C 为分段连续的参数化曲线, c_1 为 C 内像素的灰度均值, c_2 为 C 外像素的灰度均值, $\mu > 0$, $\nu > 0$, $\lambda_1, \lambda_2 > 0$ 。一般情况下, 对 λ_1 , λ_2 的推荐取值是: $\lambda_1 = \lambda_2 = 1$ 。

该方法的问题在于, 该模型对图像边缘采用的是几何测度的方式来进行控制, 这使得上述方程中的数值求解过程很困难, 特别是对于复杂的图像来说, $Length(C)$ 是很难求出的。

因此, 学者 Chan 和 Vese 提出了一种简化的 Mumford-Shad 模型, 即 Chan-Vese 分割模型^[55,56]。Chan-Vese 模型的主要思想是: 将待分割的图像分为目标图像区域 R_o 和背景图像区域 R_b , 目标图像区域 R_o 的灰度均值为 c_o , 背景图像区域 R_b 的灰度均值为 c_b 。此时, 图像分割过程就转化为寻找最优边界分割曲线 C_o , 使得分割后的图像区域与原始图像区域间的灰度值误差最小。此时, 曲线拟合能量泛函为:

$$E(c_o, c_b, C) = \mu \cdot Length(C) + \lambda_o \int_{\Omega} |u_o(x, y) - c_o|^2 dx dy + \lambda_b \int_{\Omega} |I - c_b|^2 dx dy \quad (3-33)$$

将上述未知的演化曲线 C 用水平集函数 $\phi(x, y)$ 来代替, 并且引入 Heaviside 函数, 得到:

$$\begin{aligned} E(c_o, c_b, \phi) = & \mu \cdot \int_{\Omega} \delta_{\varepsilon}(\phi(x, y)) |\nabla \phi(x, y)| dx dy \\ & + \lambda_o \int_{\Omega} |u_o(x, y) - c_o|^2 H_{\varepsilon}(\phi(x, y)) dx dy + \\ & + \lambda_b \int_{\Omega} |u_o(x, y) - c_b|^2 (1 - H_{\varepsilon}(\phi(x, y))) dx dy \end{aligned} \quad (3-34)$$

其中, H_{ε} 和 δ_{ε} 分别是 Heaviside 函数 $H(z)$ 和 Diract 函数 $\delta(z)$ 的正则化所形成的, 如下:

$$H(z) = \begin{cases} 1, & z \geq 0 \\ 0, & z < 0 \end{cases} \quad \delta(z) = \frac{dH(z)}{dz} \quad (3-35)$$

对应的偏微分方程为:

$$\left\{ \begin{array}{l} \frac{\partial \phi}{\partial t} = \delta(\phi) \left[\mu \nabla \cdot \frac{\nabla \phi}{|\nabla \phi|} - \lambda_o (u(x, y) - c_o)^2 + \lambda_b (u(x, y) - c_b)^2 \right] \\ \quad + \mu \cdot \operatorname{div} \left(\frac{\nabla \phi}{|\nabla \phi|} \right) - \nu \\ c_o = \frac{\int_{\Omega} u(x, y) H(x, y) dx dy}{\int_{\Omega} H(x, y) dx dy}, \quad c_b = \frac{\int_{\Omega} u(x, y) (1 - H(x, y)) dx dy}{\int_{\Omega} H(x, y) dx dy} \\ \phi(x, y, 0) = \phi(x, y) \end{array} \right. \quad (3-36)$$

基于中心差分法，偏微分方程的离散形式为：

$$\phi_{i,j}^{n+1} = \phi_{i,j}^n + t \cdot L(\phi_{i,j}^n) \quad (3-37)$$

其中， $\phi_{i,j}^{n+1}$ 和 $\phi_{i,j}^n$ 分别表示图像像素点 (i, j) 处的第 n 次和第 $n+1$ 次迭代得到的水平集函数值。

具体的步骤为：

- (1) 初始时刻 $n=0$ ，水平集函数初始化为符号距离函数
- (2) 根据方程(3-36)，计算出灰度均值 c_o 和 c_b
- (3) 根据(3-37)方程，计算出 $\phi_{i,j}^{n+1}$
- (4) 再次将水平集函数初始化为符号距离函数
- (5) 判断解是否收敛。如果收敛，则整个水平集函数演化过程结束，完成分割过程，得到边界曲线，否则继续跳转到步骤 (2)，继续整个循环过程。

通过整个计算过程可以看出：Chan-Vese 分割模型使用常量 c_o 和 c_b 来近似表示目标区域和背景区域的灰度均值，从而大幅的简化了 Mumford-Shad 模型的分割。

对于形态学滤波后的图像，传统的图像边缘提取算子不能提取连续的轮廓曲线，而水平集分割方法对多种样本形态，均能够提取连续的图像轮廓。同时，水平集分割能够有效地提取多个独立目标的边缘。因此，本文采取更高效的 Chan-Vese 水平集分割模型提取形态学滤波后的图像轮廓。

3.1.2 基于特征光谱监督的 LSSVM 分割方法

皮肤黑色素瘤病理诊断中，恶性黑色素细胞的形态、分布等是主要的诊断依据。然而，在 HE 染色的病理图像中，病理医生无法快速准确地识别恶性黑色素细胞，因此，为病理诊断提供恶性黑色素细胞的自动识别方法具有重要的意义。本节研究了最小二乘支持向量机(LSSVM)分割方法，并基于该方法的分割模型，提出了特征光谱监督策略，从而实现了恶性黑色素细胞的分割。

3.1.2.1 基于最小二乘的支持向量机分割算法（LSSVM）

支持向量机(Support Vector Machine, SVM)是一种经典的基于数据挖掘的机器学习方法^[57]，由 Cortes 等人于 1995 年提出的。针对传统算法中的高维度和过拟合等问题，该方法基于结构风险最小化准则，可以解决模型建立时的局部最优解和非线性问题，因此被广泛用于分类和回归问题。

在具体的非线性问题求解过程中，通过将样本对应到高维空间，该算法把非线性问题的求解转化为线性问题求解。同时在高维空间内，为了避免求解具体的映射和“位数灾难”问题，SVM 引入了核函数来代替复杂的内积运算。这样，模型的建立进而转化为不等式约束下的二次规划问题求解，大大的降低了算法的复杂度。

然而在复杂情况下，当样本的数据量和维度增长时，相应的核函数空间增长，使得模型创建过程在效率和精度上无法让人满意。针对存在的这些问题，学者通过引入最小二乘线性系统，对传统的 SVM 算法进行改进^[58]，提出了最小二乘支持向量机(Least square support vector machine, LSSVM)算法。该算法的创新性在于将原有 SVM 中的不等式约束条件替换为等式约束，将模型的求解过程变成了线性方程组的求解。此外，通过进一步的推演，把求解演化成更明确的矩阵求逆，使得算法在时间和空间上的复杂度大大降低^[59]。

具体的原理如下：

假设训练数据样本集为 $\{(x_1, y_1), \dots, (x_n, y_n)\}$ ，样本中的 $x \in R^n$ 为 n 维输入， $y_i \in R$ 为输出。首先，设非线性映射函数为 $\varphi(\cdot)$ ，即通过 $\varphi(\cdot)$ 将训练数据样本集

映射到高维空间；接着在高维空间内，具体的函数为 $f(x) = w^T \cdot \varphi(x) + b$ ，其中映射函数 $\varphi(\cdot)$ 是固定的，其数学模型如式(3-38)所示。

$$\begin{cases} \min R = \frac{1}{2} \|w\|^2 + \gamma \sum_{i=1}^n \xi_i \\ y_i = w^T \varphi(x_i) + b + \xi_i, i = 1, 2, \dots, n \end{cases} \quad (3-38)$$

上面方程式中，目标函数是结构风险的最小化，其中 R 为结构风险， w 为权值矢量， γ 为罚参数， ξ_i 为误差向量， b 为偏置量。

应用拉格朗日对偶性原理，将式(3-38)中的等式约束代入到最小化函数中，把目标函数的最小化问题转为其对偶问题，如式(3-39)所示。

$$L(w, b, \xi, \alpha) = R - \sum_{i=1}^n \alpha_i (w^T \varphi(x_i) + b + \xi_i - y_i) \quad (3-39)$$

其中， $\alpha = [\alpha_1, \alpha_2, \dots, \alpha_n]$ 为 Lagrange 乘子。

根据 Karush-Kuhn-Tucker(KKT)原理，方程(3-39)分别对 w ， b ， ξ_i 和 α_i 求偏导，同时令偏导为零，得到：

$$\begin{cases} \frac{\partial L}{\partial w} = 0 \rightarrow w = \sum_{i=1}^n \alpha_i \varphi(x_i) \\ \frac{\partial L}{\partial b} = 0 \rightarrow \sum_{i=1}^n \alpha_i = 0 \\ \frac{\partial L}{\partial \xi_i} = 0 \rightarrow \alpha_i = 2\gamma \xi_i \\ \frac{\partial L}{\partial \alpha_i} = 0 \rightarrow w^T \cdot \varphi(x_i) + b + \xi_i - y_i = 0 \end{cases} \quad (3-40)$$

这样，最优化问题的求解就转化为求解线性方程组，如式(3-41)所示：

$$\begin{pmatrix} 0 & e^T \\ e & \Omega + 2 \cdot \frac{e}{\gamma} \end{pmatrix} \begin{pmatrix} b \\ \alpha \end{pmatrix} = \begin{pmatrix} 0 \\ y \end{pmatrix} \quad (3-41)$$

其中， $e = [1, 1, \dots, 1]$ ，支持向量 $\alpha = [\alpha_1, \alpha_2, \dots, \alpha_n]$ 和 b 偏移量是模型的参数， $y = [y_1, \dots, y_N]$ 为模型输出， Ω 是大小为 $N \times N$ 的矩阵。矩阵元素如式(3-42)所示：

$$\Omega_{ij} = \varphi(x_i)^T \varphi(x_j) \quad (3-42)$$

令 $K(x_i, x_j)$ 为：

$$K(x_i, x_j) = \langle \varphi(x_i), \varphi(x_j) \rangle \quad (3-43)$$

令 $\Phi = \Omega + 2 \cdot \frac{e}{\gamma}$, 则方程(3-41)可以进一步表示为:

$$\begin{pmatrix} 0 & e^T \\ e & \Phi \end{pmatrix} \begin{pmatrix} b \\ \alpha \end{pmatrix} = \begin{pmatrix} 0 \\ y \end{pmatrix} \quad (3-44)$$

方程(3-44)的求解过程, 就是 LSSVM 模型的学习过程, LSSVM 的模型参数 $\alpha = [\alpha_1, \alpha_2, \dots, \alpha_n]$ 和偏移量 b 可以表示为:

$$\begin{cases} \alpha = \Phi^{-1}y - \Phi^{-1}e \cdot \frac{e^T \Phi^{-1}y}{e^T \Phi^{-1}e} \\ b = \frac{e^T \Phi^{-1}y}{e^T \Phi^{-1}e} \end{cases} \quad (3-45)$$

式(3-45)中, Φ 被称为 LSSVM 模型的特征矩阵, 表示如下:

$$\Phi = \begin{bmatrix} K(x_1, x_1) + \frac{1}{2\gamma} & K(x_1, x_2) & \cdots & K(x_1, x_N) \\ K(x_2, x_1) & K(x_2, x_2) + \frac{1}{2\gamma} & \cdots & K(x_2, x_N) \\ \vdots & \vdots & \ddots & \vdots \\ K(x_N, x_1) & K(x_N, x_2) & \cdots & K(x_N, x_N) + \frac{1}{2\gamma} \end{bmatrix} \quad (3-46)$$

式(3-46)中, $K(x_i, x_j)$ 为核函数。

联立方程(3-40)和(3-46), 最终得到 LSSVM 模型的回归函数, 如下所示:

$$y(x) = \sum_{i=1}^n \alpha_i K(x, x_i) + b \quad (3-47)$$

根据上述的原理阐述可知, 核函数是 LSSVM 算法中的重要部分, 其作用是
通过将输入空间映射到高维空间, 避开了直接在高维空间中进行计算, 提高了处理非线性的能力。

目前, 常用的核函数主要有以下几种: 径向基(RBF)核函数、多项式核函数以及神经网络核函数等, 不同的核函数有不同的内积形式, 具体如下所示:

径向基核函数:

$$K(x, x_i) = \exp\left(-\frac{\|x - x_i\|^2}{\sigma^2}\right) \quad (3-48)$$

多项式核函数:

$$K(x, x_i) = [(x \cdot x_i) + q]^p \quad (3-49)$$

其中, p 为多项式阶次, 当 $q > 0$ 时, 为非齐次多项式核函数; 当 $q = 0$ 时, 为齐次多项式核函数。

神经网络核函数:

$$K(x, x_i) = \tanh(\lambda(x \cdot x_i) + \nu) \quad (3-50)$$

其中, $\lambda > 0$, $\nu < 0$ 。

通过比较各类型的核函数可以看出, 径向基核函数是最简洁的, 只包含一个参数, 求解更简单、具有最高的时间复杂度。目前径向基核函数也是业界广泛采用且经过充分证明的^[60], 因此, 本文选取径向基核函数作为 LSSVM 模型的核函数。

3.1.2.2 特征光谱监督策略

LSSVM 分割方法相比 SVM 分割方法分割速度较快, 但分割精度略低于 SVM, 因此, 本节对 LSSVM 提出了改进。基于特征光谱监督的 LSSVM 分割方法是在 LSSVM 分割模型中加入目标特征光谱曲线匹配结果, 对 LSSVM 分割结果进行再分割, 从而达到更高的分割精度。特征光谱的匹配方法是, 将待分割样本的光谱曲线与特征库中的光谱曲线进行逐一计算光谱相似度, 根据光谱相似度决定该样本的类型。评价光谱相似度通常使用光谱角(SAM)匹配方法。已知样本波段数为 λ , 则单个像素的光谱特征为 $X = [x_1, x_2, \dots, x_\lambda]$, 特征光谱特征为 $X' = [x'_1, x'_2, \dots, x'_\lambda]$, 则 X 与 X' 的光谱相似度 α 为:

$$\alpha = \arccos \left(\frac{\sum_{i=1}^{\lambda} (x_i \cdot x'_i)}{\sqrt{\sum_{i=1}^{\lambda} x_i^2} \cdot \sqrt{\sum_{i=1}^{\lambda} (x'_i)^2}} \right) \quad (3-51)$$

通常会给定 α 的阈值, 超过阈值则认为不是同类物质。光谱角匹配计算速度快, 则基于特征光谱监督的 LSSVM 分割方法实现分为以下几步:

- (1) 选光谱曲线训练集合 ROI, 集合的光谱数量可根据情况决定。
- (2) 选取特征光谱库, 通常以目标区域多个相邻像素的平均光谱曲线为特征光谱曲线, 特征光谱库中特征光谱不宜过多, 过多会增加分割时间。
- (3) 对 (1) 选取的 ROI 数据集进行训练得到 LSSVM 分类模型。

(4) 将待分割像素点的光谱曲线依次输入 LSSVM 模型, 若模型输出结果判定为目标类, 则输出为目标类; 若判定不为目标类, 则将该像素点光谱曲线与特征光谱库进行匹配, 若匹配结果为目标类, 则判定其为目标类, 否则不为目标类。单个像素特征光谱监督实现如图 3-3 所示。




图 3-3 基于特征光谱监督的 LSSVM 分割方法流程图

本文提出的基于特征光谱监督的 LSSVM 分割方法, 在特征光谱的监督下, 有效地提高了 LSSVM 的分割精度, 样本实验结果见第四章。

3.2 基于 PSO 优化的极限学习机分类方法

皮肤黑色素瘤的病灶区位于皮肤组织, 由于皮肤组织的结构复杂多样, 这增加了皮肤黑色素瘤病理诊断的难度。为了提高皮肤黑色素瘤的病理诊断效率, 本节研究了基于粒子群优化的极限学习机分类方法, 该方法能够自动识别样本中的肿瘤组织。

传统的高光谱图像监督类方法有: 支持向量机(SVM)、神经网络等, 神经网络分类速度较慢, SVM 分类速度相比神经网络较快, 但若样本量较大时, SVM 建模速度也慢。然而, 在医学诊断中, 需要高效地识别出样本中的感兴趣区域, 若算法太耗时, 则应用价值不高。因此, 寻找在精度满足要求的同时, 分类算法的效率极其重要。在此背景下, 本小节研究了基于粒子群优化的极限学习机(PSO-ELM)分类方法。

神经网络是一种根据动物神经系统学习过程启发出的数学模型, 具有良好的泛化能力、自学习和自适应能力, 得到了广泛的研究和应用^[61]。其基本的构成是神经元, 整个神经元的数学模型是 $y = g(w \cdot x + b)$, 其中 x 是输入, y 是输出, w 为权重, b 为偏移量, $g(\cdot)$ 为非线性函数, 称为激励函数, 常见的激励函数有 $\text{sigmoid}(\cdot)$ 、 $\text{traingd}(\cdot)$ 等。

图 3-4 为典型的单隐含层前馈神经网络结构图。其中, $x = [x_1, x_2, \dots, x_n]$ 为输入, $y = [y_1, y_2, \dots, y_n]$ 为输出, $o = [o_1, o_2, \dots, o_n]$ 为隐含层, $w = [w_{ij}]$ 为输入层到隐含层之间的权值, $\beta = [\beta_{jt}]$ 为隐含层到输出层之间的权值。




图 3-4 典型的单隐含层前馈神经网络结构图

一般输入层和输出层之间的激励函数设为: $g(x) = x$, 那么得到的第 k 个神经元的响应为:

$$y[k] = [g(w_1 \cdot x + b_1), g(w_2 \cdot x + b_2), \dots, g(w_n \cdot x + b_n)] \beta_k + b_2 \cdot [k] \quad (3-52)$$

其中, $k = 1, 2, \dots, n$ 。

整个单隐含层前馈神经网络的紧凑表达方式为:

$$y = h(x) \cdot \beta + b \quad (3-53)$$

其中, $h(x) = [g(w_1 \cdot x + b_1), g(w_2 \cdot x + b_2), \dots, g(w_n \cdot x + b_n)]$ 为隐含层的响应向量。

在机器学习中, 学习是指在目标函数空间中, 根据训练样本集 $\{(x_1, y_1), \dots, (x_n, y_n)\}$, 找到使损失函数 C 最小的函数 f 。因此, 损失函数 C 是个重要的概念, 常见的基于欧氏距离的损失函数如下:

$$C = E[\|f(x) - t\|^2] \quad (3-54)$$

其中, t 是真实观察值, E 表示期望。

使用具体的样本 $\{(x_1, y_1), \dots, (x_n, y_n)\}$, 得到损失函数为:

$$C = \frac{1}{n} \sum_{i=1}^n \|f(x_i) - t_i\|^2 \quad (3-55)$$

其紧凑形式为:

$$C = \|T - (H\beta + b_s \otimes I_n)\|_F \quad (3-56)$$

其中,

$$T = \begin{bmatrix} t_1 \\ t_2 \\ \vdots \\ t_n \end{bmatrix} \quad (3-57)$$

$$H = \begin{bmatrix} h(x_1) \\ h(x_2) \\ \vdots \\ h(x_n) \end{bmatrix} \quad (3-58)$$

目前常见的求解算法是反向传播算法(BP 算法)^[62], 其学习速度慢。BP 算法每次更新迭代需要更新 $n \cdot (L+1) + L \cdot (m+1)$ 个值, 其所花费的时间往往超过了容忍时间。经常一个单隐层神经网络的训练需要几个小时甚至几天时间。

针对这种问题, 2004 年, 新加坡南洋理工学院黄广斌教授^[63]在深入的研究了单隐层神经网络后, 提出了一种人工神经网络的新训练算法: 极限学习机 (Extreme Learning Machine, ELM)。其基于两个基本的理论^[64]:

理论 1: 给定一个标准的单隐层前馈神经网络, 以及训练样本集 $\{(x_1, y_1), \dots, (x_n, y_n)\}$, $x_j \in R^n, y \in R^m$, 若激励函数满足在任意区间上无限可微, 则对于在 R^n 和 R 空间的任意区间内, 根据任意连续的概率分布随机生成的 w_i 和 b_i , 都有:

(1) 隐藏层响应矩阵 H 可逆

(2) $\|T - H\beta\|_F = 0$ 成立

理论 2: 给定一个标准的单隐层前馈神经网络、训练样本集 $\{(x_1, y_1), \dots, (x_n, y_n)\}$, $x_j \in R^n, y \in R^m$, 以及任意小的正数 ε , 若激励函数满足在任意区间上无限可微, 则对于任意在 R^n 和 R 空间的任意区间内的概率分布随机生成的 w_i 和 b_i , 都有: 存在 $L \leq N$, 使得 $\|T - H\beta\|_F \leq \varepsilon$ 以概率一成立。

根据以上的两个理论得到: 单隐层前馈神经网络不再需要对 w_i 和 b_i 进行调整, w_i 和 b_i 可以根据连续概率分布随机生成; 同时, 输出层的偏执 b 也不再需要。因此, 神经网络仅需要确定输出权重 β 即可, 如式(3-59)所示:

$$T = H\beta \quad (3-59)$$

对上面方程的求解, 就是整个神经网络的构建。根据理论 2 可知, 当 $L = N$ 的时候, 矩阵 H 是可逆的, 进而可以得到 $\beta = H^{-1} \cdot T$ 。

然而大多数情况下, 隐藏神经元的个数 L 是远远小于训练样本个数 N , 因此需要转而求解使得损失函数 C 最小的解, 即:

$$\hat{\beta} = \arg \min_{\beta} \|T - H\beta\|_F \quad (3-60)$$

根据极小范数准则, 方程(3-60)存在最小二乘解:

$$\hat{\beta} = H^+ \cdot T \quad (3-61)$$

其中, H^+ 为 H 的 Moore-Penrose 广义逆。

在对 H^+ 进行计算的时候, 常用方法如下:

$$\begin{cases} H^+ = (H^T H + \lambda I)^{-1} H^T, L > N \\ H^+ = H^T (H^T H + \lambda I)^{-1}, L \leq N \end{cases} \quad (3-62)$$

因此, ELM 算法的基本实现步骤如下:

(1) 初始化: 设置隐含层单元个数, 输入层到隐含层之间的权重值 w 以及隐含层的随机偏差 b 可以通过随机数产生

(2) 计算矩阵 H : 选择无线可微分的神经元激活函数, 来计算得到

(3) 根据式(3-61), 计算出 $\hat{\beta}$

对于传统的单隐层神经网络, 极限学习机的优势在于:

1) 建模速度很快, 只需要将输出权值 β 求出即可, 而传统的 BP 方法需要不断地迭代, 且每次迭代需要计算 $n \cdot (L+1) + L \cdot (m+1)$ 个值, 学习率也较小, 使得学习时间大大加长。

2) 大多数情况下, 极限学习机的泛化能力要超过类似误差的反向传播算法等。

3) 能够得到唯一的最优解。

ELM 算法中, 隐藏节点参数是随机产生的, 相对于传统的算法来说, 需要更多的隐藏节点才能获取更好的模型精度。因此, 选择恰当的隐藏层节点数量, 对于提高 ELM 算法的性能有重要的意义。对于 ELM 的参数选取, 目前仍然没

有统一的方法。相对于其他现代优化算法，粒子群算法在搜索速度和时间空间复杂度上有较大的优势，此外算法原理和实现过程也更简单，在近些年来得到了广泛的应用。因此，本文采用粒子群算法(PSO)来优化 ELM。PSO 优化原理如下：

1) 初始化种群：种群规模设为 N ，设输入层的神经元数量为 m ，隐藏层节点数为 h 。

2) 计算粒子的适应度：采用 ELM 对初始种群中的粒子进行训练，并计算出每个粒子的预测误差，作为适应度值。

3) 更新个体极值和群体极值：每次迭代后，更新个体极值和群体极值。

4) 判断结果是否满足目标精度，不满足则跳转到步骤 2)，满足则结束迭代，全局最优解粒子的位置即为最优解。

粒子群算法优化步骤如图 3-5 所示：




图 3-5 粒子群算法对 ELM 模型的寻优流程

基于 PSO 优化的 ELM 算法能够在满足分类精度的同时，分类速度高于 SVM 和 BP 分类算法。因此，在对分类精度要求不高的实践中，基于 PSO 优化的 ELM 分类算法更适用。

3.3 量化评价方法

根据疾病检测的阴性、阳性结果判定方式,本文引进混淆矩阵概念计算算法的精度。设原图像整体数据集为 I ,目标中标准阳性数据集为 $S, S \subset I$,使用本文方法得到目标结果阳性数据集为 $W, W \subset I$ 。如图 3-6 所示,设 S_- (红色)为标准阳性数据集 S 与方法结果阳性数据集 W 不重叠部分, S_+ (蓝色)为标准阳性数据集 S 与方法结果阳性数据集 W 重叠部分; W_- (黄色)为方法结果阳性数据集 W 与标准阳性数据集 S 不重叠部分,即 $\overline{W} = S_+$; I_- (灰色)为原图像数据集除去结果数据集与标准数据集部分。




图 3-6 精度计算区域分布图

分别定义真阳率(True Positive, TP)、真阴率(True Negative, TN)、假阳率(False Positive, FP)、假阴率(False Negative, FN)如下。

(1) 真阳率(TP)

真阳率表示正确识别出的阳性数据集部分,占标准阳性数据集的比例,也称算法判断为真的正确率,即实际为正样本,同时也被判定为正样本的比例,计算公式如式(3-63)所示。

$$TP = \frac{S \cap W}{S_+ + S_-} = \frac{S_+}{S_+ + S_-} \quad (3-63)$$

(2) 真阴率(TN)

真阴率表示正确识别出的阴性数据集部分,占标准阴性数据集的比例,也称算法判断为假的正确率,即实际为负样本,同时被判定为负样本的比例,计算公式如式(3-64)所示。

$$TN = \frac{I_-}{S} = \frac{I_-}{I_- + W_-} \quad (3-64)$$

(3) 假阳率(FP)

假阳率表示方法错误识别为阳性数据集部分,占标准数据集阴性的比例,也称为误报率,即实际为负样本,被判定为正样本的比例,计算公式如式(3-65)所示。

$$FP = \frac{W_-}{S} = \frac{W_-}{I_- + W_-} \quad (3-65)$$

(4) 假阴率(FN)

假阴率表示方法未识别到的阳性数据集部分,占标准阳性数据集的比例,也称为漏报率,即实际为正样本,但被判定为负样本的比例,计算公式如式(3-66)所示。

$$FN = \frac{S_-}{S_+ + S_-} \quad (3-66)$$

根据 TP、TN、FP、FN 分别计算了分类器的三个评价参数,分别为准确率、敏感性、特异性。准确率表示了分类器对整个样本将正判定为正、负判定为负的能力;敏感性表示分类器正确判断的比例占总正样本的比例;特异性表示负样本预测结果与实际负样本的比例。计算公式如下:

a) 准确率(Accuracy)

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \times 100\% \quad (3-67)$$

b) 敏感性(Sensitivity)

$$Sensitivity = \frac{TP}{TP + FN} \times 100\% \quad (3-68)$$

c) 特异性(Specificity)

$$Specificity = \frac{TN}{TN + FP} \times 100\% \quad (3-69)$$

准确性、敏感性、特异性三个评价参数值越大代表分类器性能越好。第四章评价算法的性能均为本小节介绍的计算方式。

3.4 本章小结

结合显微高光谱图像处理方法,本章提出了两种显微高光谱图像分割方法和一种分类方法:基于核最小噪声分离(KMNF)的分割方法、基于特征光谱监督的最小二乘支持向量机(CSS-LSSVM)分割方法和基于粒子群优化的极限学习机(PSO-ELM)分类方法。

首先,为了分割皮肤颗粒层,本章提出了基于 KMNF 的分割方法,分别研究了传统高光谱图像特征提取方法 PCA 和 MNF 的原理,并引出 MNF 的改进方法 KMNF 的原理,相比 MNF, KMNF 保留了光谱数据的非线性特征。研究了数学形态学滤波原理,设计了多尺度形态学滤波算子;研究了传统图像边缘滤波算子和水平集分割原理。KMNF 结合形态学滤波和水平集方法能够有效地分割出皮肤颗粒层的形态。其次,为了分割恶性黑色素细胞,本章提出了 CSS-LSSVM 分割方法,从 SVM 原理出发,提出其改进方法 LSSVM,为了进一步提高 LSSVM 算法分割精度,提出了特征光谱监督策略,该方法建模速度快且分割精度较高。

然后,为了快速识别样本中的肿瘤组织,本章采用了 PSO-ELM 分类方法,以传统的神经网络算法原理为基础,验证了 ELM 分类方法只需输入隐含层单元个数,便可快速得到分类结果,并且提出了 PSO 方法对 ELM 的输入参数进行优化,进一步提高了分类精度。

最后,为了验证上述算法的性能,本章介绍了定量化评价方法。

第四章 皮肤黑色素瘤识别及定量化分析

目前,皮肤黑色素瘤病理诊断中,尚无辅助技术为病理医生提供参考。病理医生根据自身诊断经验做出判断,存在一定的人为误差,一项病例往往需要三个或者三个以上的病理专家才能确诊,这耗费了大量的人力和时间。若存在辅助技术能够自动获取肿瘤的大小、深度等指标,则可为病理医生的诊断提供重要的数据参考。

根据第三章提出的显微高光谱图像识别方法,本章对 2.3.2 节中描述三类皮肤黑色素瘤样本进行识别以及定量化分析。首先,使用 3.1.1 节提出的基于 KMNF 的分割方法,对皮肤黑色素瘤样本类型 1 进行颗粒层的分割,分别对比了传统方法和高光谱图像方法的分割结果,并计算各方法的分割精度。其次,使用 3.1.2 节提出的基于特征光谱监督的 LSSVM 分割方法,对皮肤黑色素瘤样本类型 2 进行恶性黑色素细胞分割,展示了该方法与 SVM 分割结果并定量化计算分割精度。然后,采用 3.2 节研究的基于 PSO-ELM 分类方法,对皮肤黑色素瘤样本类型 3 进行肿瘤区域的识别,展示了该方法与 SVM 识别结果和算法耗时。最后,利用 4.1 节的颗粒层分割结果,同时使用基于特征光谱监督的 LSSVM 分割方法分割皮肤黑色素瘤样本类型 1 中的恶性黑色素细胞,采用 3.1.1.3 节中水平集分割得到颗粒层和恶性黑色素细胞的边界,通过两者边界计算出皮肤黑色素瘤的入侵深度。

4.1 基于高光谱图像形态分割的皮肤颗粒层分割

在皮肤黑色素瘤入侵深度计算中,通常将颗粒层作为入侵深度计算的起始边界。皮肤从上到下主要分为表皮层、真皮层和皮下组织。表皮层从上到下分为角质层、颗粒层、有棘层和基底层。颗粒层位于角质层下方,角质层越厚,颗粒层也越厚。颗粒层通常由 2-4 层细胞组成,细胞呈梭形,颗粒层能够阻止外物入侵,并且具有折射反射过滤紫外线的功能。HE 染色中,颗粒层通常呈现深紫蓝色,与表皮层其它组织染色接近,无法通过形态学滤波等基础图像处理识别样本中的

颗粒层。皮肤颗粒层的准确识别有利于提高皮肤黑色素瘤入侵深度计算的精度，而准确的入侵深度与皮肤黑色素瘤手术切除大小和预后至关重要，这决定了皮肤黑色素瘤的治愈几率，因此，皮肤颗粒层的准确识别极其重要。

4.1.1 病理图像分割结果

皮肤黑色素瘤病理图像处理结果如图 4-1 所示，(a)为病理图像视场的彩色图片，(b)为图(a)灰度化结果，(c)为对(b)进行 3.1.1.2 节介绍的形态学滤波的结果，(d)为图(c)中红色矩形区域放大效果，由(c)、(d)可知，对病理图像进行简单的形态学处理无法识别皮肤颗粒层。




图 4-1 彩色图像处理结果

基于病理图像，Xu 等提出了皮肤颗粒层的识别方法^[65]，该方法需要首先识别表皮层，再识别颗粒层，表皮层和颗粒层的识别均用到不同算法，步骤繁琐且复杂。Mokhtari 等使用形态学滤波、自适应增强、阈值转换相结合分割出皮肤颗粒层^[66]。

上述现有的基于病理图像的皮肤颗粒层识别方法步骤繁琐,且样本中角质层薄且稀疏,对颗粒层识别的干扰较小。本文中的皮肤黑色素瘤样本角质层厚,与颗粒层界限不明显,这极大的增加了颗粒层识别的难度。基于显微高光谱成像系统采集的皮肤黑色素瘤样本中保存了样本更多的空间信息,根据显微高光谱图像的丰富空间信息,可采用较简单的方法直接识别颗粒层。

4.1.2 基于 KMNF 的分割结果

本小节中,采用 3.1.1 节提出的基于 KMNF 的分割方法,对 2.3.2 节的皮肤黑色素瘤样本类型 1 进行了颗粒层的分割。该方法步骤为:

(1) 首先,采用 3.1.1.1 节提出的 KMNF 特征提取方法对光谱校正后的数据进行处理,使图像的主要特征集中到前几个波段,并降低图像噪声。

(2) 然后,选取颗粒层形态特征明显的波段,采用 3.1.1.2 节的滤波算子,对其进行形态学滤波,并选取滤波后的最大连通域。

(3) 最后,采用 3.1.1.3 节的水平集分割方法提取颗粒层轮廓。

基于 KMNF 分割方法对皮肤颗粒层的分割结果如图 4-2 所示,(a)为样本彩色视场对照图像,(b)为光谱校正后显微高光谱图像数据中波长为 658nm 的二维图像,图像中颗粒层含有 2-3 层细胞。(c)为对样本数据进行 KMNF 处理后得到结果的第 6 波段数据。(d)为利用图 3-2 中的滤波器对(c)进行数学形态学滤波,并识别出最大连通域的结果。(e)为对(d)进行水平集分割,得到的皮肤颗粒层的轮廓。(f)为将轮廓结果(e)与原高光谱图像视场(b)相叠加的结果。由(f)可以看出,红色曲线表示基于 KMNF 分割方法识别出的皮肤颗粒层的轮廓,结合皮肤颗粒层的病理特性,可以看出,基于 KMNF 分割方法分割出的结果与实际轮廓基本吻合。说明了基于 KMNF 分割方法能够有效地分割出皮肤颗粒层。




图 4-2 皮肤颗粒层分割结果

4.1.3 PCA、MNF、KMNF 分割结果对比

在 3.1.1.1 节中,研究了三种高光谱图像特征提取方法:PCA、MNF、KMNF。本节选取四个样本,采用 4.1.2 节的方法步骤,对三种方法进行实验。皮肤颗粒层的分割结果如图 4-3 所示,基于 PCA 的分割方法对颗粒层的分割结果较差,由于噪声的影响,分割结果中存在较多负样本区域,如样本 2、样本 3、样本 4。基于 MNF 的分割方法对颗粒层的分割结果相比基于 PCA 的分割方法较好,滤

除了非目标区域，基本保留了颗粒层的主要形态，但由于样本视场的差异，该方法也会存在人眼能识别的明显的误差，如图 4-3 中样本 2，基于 MNF 的分割方法不能完全识别出颗粒层，并将角质层部分识别为颗粒层。基于 KMNF 的分割方法能够准确地分割出颗粒层，该方法相比前面两种方法能够较完全的保留颗粒层的形态。因此，通过三种方法实验结果对比可知，基于 KMNF 的分割方法对皮肤颗粒层的分割结果更精确。




图 4-3 三种方法颗粒层分割结果对比图

目前，病理诊断均以病理医生人眼判定为标准，因此，为了验证算法的有效性，图 4-3 中四个样本人工手动圈出的颗粒层轮廓均在病理医生的指导下圈出，且通过三位病理专家核实。以手动圈出的皮肤颗粒层为标准，根据 3.3 节提出的量化评价方法，计算三种方法的评价参数：真阳率(TP)、真阴率(TN)、假阳率(FP)、假阴率(FN)、准确率(Accuracy)、敏感性(Sensitivity)、特异性(Specificity)如表 4-1 所示。由于准确率代表了算法总体识别正负样本的能力，因此本节主要关注算法的准确率，由表 4-1 中准确率的数据可得到三种方法准确率对比图 4-4。

表 4-1 皮肤颗粒层分割结果精度计算

样本数		1	2	3	4
TP	PCA	71.47	40.92	42.94	50.92
	MNF	81.62	59.64	46.71	55.05
	KMNF	87.90	64.05	64.84	79.54
TN	PCA	99.36	93.63	96.40	95.59
	MNF	99.35	98.52	99.97	97.55
	KMNF	98.72	99.40	99.85	96.79
FP	PCA	0.64	6.37	3.60	4.41
	MNF	0.65	1.48	0.03	2.45
	KMNF	1.28	0.60	0.15	3.21
FN	PCA	28.53	59.08	57.06	49.08
	MNF	18.38	40.36	53.29	44.95
	KMNF	12.10	35.95	35.16	20.46
Accuracy	PCA	85.42	67.28	69.67	73.25
	MNF	90.48	79.08	73.34	76.30
	KMNF	93.31	81.73	82.35	88.16
Sensitivity	PCA	71.47	40.92	42.94	50.92
	MNF	81.62	59.64	46.71	55.05
	KMNF	87.90	64.05	64.84	79.54
Specificity	PCA	99.36	93.63	96.40	95.59
	MNF	99.35	98.52	99.97	97.55
	KMNF	98.72	99.40	99.85	96.79

由图 4-4 中 PCA、MNF、KMNF 分割结果准确率对比可知, 基于 MNF 分割方法准确率和敏感性均高于基于 PCA 的分割方法, 基于 KMNF 的分割方法对皮肤颗粒层分割的准确率和敏感性均高于基于 MNF 分割方法。三种方法的特异性均能达到 90%以上。对于所有实验样本, 基于 KMNF 的分割方法的准确性均能

达到 80% 以上, 样本 1 的准确率更能达到 90% 以上。可见, 本文提出的基于 KMNF 的分割方法对皮肤黑色素瘤的识别精度高于基于 PCA、MNF 分割方法。将基于 KMNF 的分割方法用于皮肤颗粒层的分割, 为皮肤入侵深度的计算提供了更准确的边界。




图 4-4 PCA、MNF、KMNF 分割结果准确率对比图

4.2 基于特征光谱监督的恶性黑色素细胞分割

皮肤黑色素瘤是源于黑色素细胞的癌变, 因此, 恶性黑色素细胞是皮肤黑色素瘤诊断中重点观察对象。在没有明显病变组织的皮肤黑色素病例中, 病理诊断判定肿瘤的大小和边界依据恶性黑色素细胞的分布, 因此, 准确的识别出尽可能多的恶性黑色素细胞对后期的治疗极其重要。在 HE 染色样本的显微视场下, 皮肤黑色素瘤样本中恶性黑色素细胞形态特征较多, 人眼观察存在一定的主观误差, 而且非常耗时, 这给皮肤黑色素瘤病理的快速诊断增加了难度。因此, 计算机自动识别出样本中的恶性黑色素细胞, 能够更客观地进行快速的病理诊断。

本节中, 采用 3.1.2 节提出的基于特征光谱监督的最小二乘支持向量机 (CSS-LSSVM) 算法, 分割了 2.3.2 节皮肤黑色素瘤样本类型 2 中的恶性黑色素细胞, 为病理诊断提供更可靠的位置标注。

恶性黑色素细胞识别结果如图 4-5 所示, (a)为彩色视场对比图像, 可知, 恶性黑色素细胞聚集分布, (b)为波长为 658nm 的单波段高光谱图像视场, (c)为 SVM 分割结果, (d)为 CSS-LSSVM 分割结果。(d)中样本训练集和测试集与(c)相同, 选取了 10 条目标特征光谱曲线作为光谱特征库。由图 4-5 可见, CSS-LSSVM 分割方法相比 SVM 分割方法, 能够识别出更多的细胞区域。




图 4-5 恶性黑色素细胞分割结果

目前, 病理诊断均以病理医生人眼判定为标准, 因此, 本节中, 皮肤黑色素瘤样本中的恶性黑色素细胞是在病理医生指导下圈出, 且通过三位病理专家核实。四个样本实验结果如图 4-6 所示。




图 4-6 恶性黑色素细胞分割对比图

以手动圈出的恶性黑色素细胞为标准，根据 3.3 节提出的定量化评价方法，计算两种方法的评价参数：真阳率(TP)、真阴率(TN)、假阳率(FP)、假阴率(FN)、准确率(Accuracy)、敏感性(Sensitivity)、特异性(Specificity)如表 4-2 所示。由于准确率代表了算法总体识别正负样本的能力，因此本节主要关注算法的准确率，由表 4-2 中准确率的数据可得到三种方法准确率对比图 4-7。

表 4-2 恶性黑色素细胞分割结果精度

样本数		1	2	3	4
TP	SVM	38.05	60.04	56.50	58.32
	CSS-LSSVM	77.91	79.33	76.72	76.54
TN	SVM	99.15	98.64	98.01	98.64
	CSS-LSSVM	94.13	95.66	95.33	97.15
FP	SVM	0.85	1.36	1.99	1.36
	CSS-LSSVM	5.87	4.34	4.67	2.85
FN	SVM	61.95	39.96	43.50	41.68
	CSS-LSSVM	22.09	20.67	23.28	23.46
Accuracy	SVM	68.60	79.34	77.25	78.48
	CSS-LSSVM	86.02	87.49	86.02	86.85
Sensitivity	SVM	38.05	60.04	56.50	58.32
	CSS-LSSVM	77.91	79.33	76.72	76.54
Specificity	SVM	99.15	98.64	98.01	98.64
	CSS-LSSVM	94.13	95.66	95.33	97.15

由图 4-7 可知, CSS-LSSVM 对样本中恶性黑色素细胞的分割准确率均高于 SVM, 且能达到 85%以上。由表 4-2 数据可知, CSS-LSSVM 算法的敏感性均高于 SVM, 即 CSS-LSSVM 能够检测出恶性黑色素细胞的概率高于 SVM。敏感性的提高往往会降低特异性, 四个样本中 CSS-LSSVM 算法的特异性均低于 SVM, 即 CSS-LSSVM 能够检测出非恶性黑色素细胞的概率低于 SVM。可见, CSS-LSSVM 在识别出更多的恶性黑色素细胞的同时, 可能会将少数非恶性黑色素细胞误识别。由于皮肤黑色素瘤的转移性极强, 在皮肤黑色素瘤诊断中, 漏识别恶性黑色素细胞可能会导致癌细胞转移, 极大影响患者的存活率, 因此, 相比 SVM 分割方法, CSS-LSSVM 分割方法更适合作为恶性黑色素细胞的识别算法。




图 4-7 SVM 和 CSS-LSSVM 分割准确率对比图

4.3 基于 PSO-ELM 的皮肤黑色素瘤分类

皮肤黑色素瘤样本类型 3 中，病变组织边界不清晰，通过人眼准确的识别肿瘤的病灶区边界比较困难。辅助方法能够为皮肤黑色素瘤的识别和分析提供初步标记视场和定量化数据，这极大方便了皮肤黑色素瘤的初步诊断。本节采用基于 PSO-ELM 的高光谱图像分类方法，对比方法为传统的 SVM。已知经过光谱校正后的数据像素总量为 $1800\times1300\times60$ ，若用全部数据进行分类，则计算量大，对电脑性能要求较高。由于相邻像素之间的相关性较高，单波段图像的冗余较高。因此，本节对校正后的光谱数据进行重采样，设重采样频率为 2，则重采样的像素总量为 $900\times650\times60$ 。SVM 与 PSO-ELM 分类方法的主要输入参数如表 4-3 所示。

表 4-3 SVM 与 PSO-ELM 分类方法主要输入参数

SVM		PSO-ELM	
核函数:	径向基函数	PSO 总群规模:	300
参数 γ :	0.017		
惩罚参数:	100	激活函数类型:	Sigmoidal 函数

实验系统为 64 位 Windows7，处理器为 Intel(R) Core(TM) i5-4590 CPU @3.30GHz，内存 4GB，软件为 R/MATLAB2015b。本节针对两例皮肤黑色素瘤

样本类型 3 进行实验结果展示。两例样本视场分别被分为五类(可根据样本视场组织的分布不同, 调整样本的分类数量), 选定训练集, 根据表 4-3 的参数, 样本 1 分类结果如图 4-8 所示。




图 4-8 样本 1 皮肤黑色素瘤分类结果

图 4-8 中, (a)为样本彩色图像视场, 其中红色矩形区域为人眼大致识别出的主要的肿瘤区域, 肿瘤病灶区在表皮层与真皮乳头层交界处, 可见肿瘤区域着色不均匀, 细胞形态异常。(b)为高光谱图像波长为 658nm 的灰度图像, 根据(a)可以得到(b)中红色矩形区域为主要肿瘤区域。(c)、(d)分别为 SVM 分类结果和 PSO-ELM 分类结果, 由(c)、(d)可知, 两种方法都能将样本中主要病变区域识别出, 但识别效果不一样, 在肿瘤区域与表皮层交界处以及正常组织中, PSO-ELM 能够更多地识别出肿瘤区域, 且肿瘤边界更加清晰。可见, PSO-ELM 分类方法能为皮肤黑色素瘤的诊断提供更清楚的肿瘤边界和更丰富的肿瘤区域识别。

表 4-4 展示了各类型训练样本量，以及两种方法各类分类结果比例。输入类型为五类，如表 4-4 所示，五类组织分别选取不同的特征量，例如病变组织选取 503 个特征点，每个特征点包含 60 个波段的特征值，将每个类别的特征向量矩阵作为训练样本，剩余样本作为测试样本。各种类别识别结果占图像总视场的百分比如表 4-4 所示， P_{SVM} 为 SVM 分类结果比例， $P_{PSO-ELM}$ 为 PSO-ELM 分类结果比例， P_{Error} 为 P_{SVM} 与 $P_{PSO-ELM}$ 差的绝对值。

由表 4-4 中 P_{Error} 可知，两种方法对表皮层、恶性黑色素细胞、样本空白区域三种类别识别结果差在 0%-2% 范围内，对病变组织和正常组织识别结果差在 5%-7% 范围内。PSO-ELM 识别速度比 SVM 快 15S。

表 4-4 样本 1 分类输入特征量与结果

类型	特征向量	P_{SVM} (%)	$P_{PSO-ELM}$ (%)	P_{Error} (%)
病变组织	503×60	19.49	25.68	6.19
表皮层	524×60	42.59	42.20	0.39
正常组织	509×60	24.89	19.63	5.26
恶性黑色素细胞	340×60	7.64	6.15	1.49
样本空白区域	466×60	5.39	6.34	0.95
时间(S)		44	29	15

样本 2 的分类结果如图 4-9 所示，其中，(a)为样本彩色视场，其中红色矩形区域为人眼大致识别出的主要的肿瘤区域，可见该样本的肿瘤区域主要存在于视场的右半部分。样本中病变区域存在真皮层和表皮层，肿瘤区域呈棕色，边缘伴随炎症反应，恶性黑色素细胞胞浆明显，高倍显微镜下可见有丝分裂。(b)为高光谱图像波长为 658nm 的单波段图像，可见样本视场中不同组织区域灰度值不一样，根据(a)可以得到(b)中红色矩形区域为主要肿瘤区域。(c)、(d)分别为 SVM 分类结果和 PSO-ELM 分类结果，由(c)、(d)可知，两种方法都能将样本中主要病变区域识别出，但识别效果不一样，PSO-ELM 分类方法相比 SVM，将表皮层中更多的组织识别为肿瘤组织，肿瘤区域与正常组织边界更加清晰。




图 4-9 样本 2 皮肤黑色素瘤分类结果

PSO-ELM 与 SVM 的输入参数如表 4-3 所示，训练样本量与分类结果如表 4-5 所示。分类结果对比结果与样本 1 结果相似，表皮层、恶性黑色素细胞、样本空白区域三种类别识别结果差在 0%-2%的范围，病变组织和正常组织识别结果差在 5%-7%的范围。针对视场样本分布可知，样本 2 视场主要组织为病变组织，占总视场 40%-55%，其次为正常组织，因此，在两种方法下，两种组织的分类结果相差较大。样本 2 两种方法从训练到最终分类完成时间相差 9 秒，表明 PSO-ELM 在分类时间上更优于 SVM。

在皮肤黑色素瘤病理诊断中，快速确定肿瘤的更多病灶区是主要任务，若不能够识别完整的病变组织，则对后续手术切除范围具有较大的影响，若切除不彻底，会导致癌细胞转移，从而影响患者的预后。因此，皮肤黑色素瘤病灶区的完整识别十分重要。

两个样本的实验结果表明，在训练样本和测试样本完全相同的情况下，PSO-ELM 能够识别出更多的肿瘤组织，正常组织与肿瘤组织的边界更加清晰，且分类速度明显快于 SVM。因此，在皮肤黑色素瘤病理诊断中，为了达到更高效的诊断，PSO-ELM 分类方法比 SVM 更适合。

表 4-5 样本 2 分类输入特征量与结果

类型	特征向量	$P_{SVM}(\%)$	$P_{PSO-ELM}(\%)$	$P_{Error}(\%)$
病变组织	463×60	44.87	50.85	5.98
表皮层	500×60	13.24	12.13	1.11
正常组织	527×60	26.98	20.39	6.59
恶性黑色素细胞	398×60	8.90	9.87	0.97
样本空白区域	567×60	6.01	6.76	0.75
时间 (S)		26	17	9

4.4 皮肤黑色素瘤入侵深度测量方法

皮肤黑色素瘤的治疗主要包括外科治疗、靶向治疗、化学治疗、生物化疗等^[67]。外科治疗是现有的最有效和首选的治疗方法，是通过对原发病灶的切除，有效地阻止肿瘤扩散，对原发病灶的切除是否彻底也是影响预后的一个直接因素。外科治疗最重要的是确定肿瘤的边界，不同类型、不同部位、不同大小的皮肤黑色素瘤的切除边界不一致。国外学者研究表明，并不是切除病灶边界越大就能降低复发率和转移率^[68,69]，对于面部病灶则需要尽可能缩小切除范围的同时，保证切除彻底，这无疑加大了手术难度。

现阶段，皮肤黑色素瘤入侵深度的判定是通过病理医生在显微视场下确定肿瘤的边界，根据肿瘤边界估算入侵深度。或是在手术中，将切除组织制成快速冰冻切片，判断切片中是否含有肿瘤组织来确定肿瘤的边界。现有的方法中无法给出皮肤黑色素瘤入侵深度准确的定量化指标，由于人眼的误差，导致估算的入侵深度存在一定的偏差。因此，本节基于显微高光谱图像数据，实现了自动测量皮肤黑色素瘤的入侵深度，为病理诊断和手术切除提供了入侵深度的定量化参考数据。

本节采用皮肤黑色素瘤样本类型 1 计算皮肤黑色素瘤的入侵深度。首先通过 3.1.1 节提出基于 KMNF 分割方法分割皮肤颗粒层。然后通过 3.1.2 节提出的 CSS-LSSVM 分割方法分割视场中的恶性黑色素细胞。最后基于颗粒层和恶性黑色素细胞边界计算皮肤黑色素瘤入侵深度。颗粒层识别结果如图 4-2 中(e)所示, 可将颗粒层边界分为内边界(靠近真皮层部分)与外边界(靠近角质层部分), 计算黑色素瘤入侵深度以外边界为准, 因此可以首先去除无意义的的数据, 减少计算量。同理, 对于样本中的恶性黑色素细胞, 以颗粒层外边界斜率为参照, 去掉较近的恶性黑色素细胞数据, 保留较远的数据。图 4-10 中, 红色曲线为颗粒层的外边界, 蓝色为筛选出的恶性黑色素细胞边界。




图 4-10 颗粒层外边界与恶性黑色素细胞边界图

设颗粒层的外边界曲线点集合为 $D(\Phi_i(x, y) | i \in 1, 2, \dots, p)$, p 为颗粒层外边界曲线像素点个数。设恶性黑色素细胞边界曲线点的集合为 $M(\Gamma_j(x, y) | j \in 1, 2, \dots, q)$, q 为恶性黑色素细胞边界像素点个数。皮肤黑色素瘤入侵深度自动计算方法流程图如图 4-11 所示。




图 4-11 皮肤黑色素瘤入侵深度计算流程图

计算皮肤黑色素瘤深度步骤为:

(1) 数据采集

由于相邻像素之间距离相差较小, 为了减少计算量, 对曲线 D 、 M 进行重采样。设置采样距离为 d 个像素点, 符号 $\lfloor$ 表示下取整, 则采样后的颗粒层和恶性黑色素细胞的边界集合分别表示为:

$$D_d(\Phi_i(x, y) | i \in 1, 2, \dots, \lfloor(p/d)\rfloor) \quad (4-1)$$

$$M_d(\Gamma_j(x, y) | j \in 1, 2, \dots, \lfloor(q/d)\rfloor) \quad (4-2)$$

(2) 计算肿瘤入侵深度估计值

设 E_k 为一组坐标对, 集合 M_d 中的第 i 个点为 Φ_i , 依次计算 Φ_i 与集合 D_d 中每个点的距离, 选取距离最小的点记录为 E_k , 即:

$$E_k \langle \Phi_i(x, y), \Gamma_j(x, y) \rangle = \min \|\Phi_i - \Gamma_j\|, \Phi_i \in D_d, \Gamma_j \in M_d \quad (4-3)$$

$\|\cdot\|$ 表示两点之间的欧式距离, 设坐标对 $\tilde{E}$ 为 E_k 中距离最大的坐标对, 即

$$\tilde{E} \langle \Phi_m(x, y), \Gamma_m(x, y) \rangle = \max_E E_k, k \in 1, 2, \dots, \lfloor(q/d)\rfloor \quad (4-4)$$

则 $\tilde{E}$ 表示恶性黑色素细胞距离颗粒层最远点。

(3) 计算入侵深度最终值

为了提高肿瘤入侵深度计算结果精度, 对找到的最大距离对求解领域最大值, 设 $Deep$ 为黑色素瘤的深度, 则

$$Deep = \max \|\Phi_i(x, y) - \Gamma_j(x, y)\|, m-d < i, j < m+d \quad (4-5)$$

该计算方法能够在确保精度的同时减少了计算量。样本的入侵深度计算结果如图 4-12 所示。




图 4-12 皮肤黑色素瘤入侵深度测量结果

图4-12中黄色箭头为计算机自动计算出样本肿瘤入侵深度,为1379.5 pixels,根据灰度 CCD 参数及放大倍数可计算实际入侵深度约 0.090mm。对 4.1 节中的样本分别计算皮肤黑色素瘤的入侵深度结果如图 4-13 所示。




图 4-13 多样本皮肤黑色素瘤入侵深度结果展示

基于之前章节的研究，本节提出了皮肤黑色素瘤入侵深度的自动测量方法，为皮肤黑色素瘤的诊断以及手术治疗提供了定量化参考数据。

4.5 本章小结

本章以 2.3.2 节介绍的三类皮肤黑色素瘤样本数据为基础，采用第三章提出的识别方法，实现了皮肤黑色素瘤的识别及定量化分析。首先，本章分别展示了病理图像和显微高光谱图像的皮肤颗粒层分割结果，结果表明，显微高光谱图像能够更容易地分割皮肤颗粒层。基于显微高光谱图像，本章展示了基于 PCA、MNF、KMNF 的三种分割方法分割结果，并定量化计算了各个方法的分割精度，实验结果表明，基于 KMNF 的分割方法对颗粒层的分割精度高达 80% 以上。其次，本章展示了 SVM 和 CSS-LSSVM 两种分割方法对恶性黑色素细胞的分割结果，定量化计算了两种方法的分割精度，结果表明，CSS-LSSVM 分割精度达到 85% 以上。最后，本章展示了 SVM 和 PSO-ELM 分类方法的分类结果和耗时，定量化对比分析了两种算法的分类结果，结果表明，PSO-ELM 分类方法能够识别出样本中更多的肿瘤组织，且分类速度更快。最后，本章提出了皮肤黑色素瘤入侵深度的测量方法，并通过颗粒层和恶性黑色素细胞的分割结果，自动测量了皮肤黑色素瘤的入侵深度，为该病的诊断和手术治疗提供了有效的参考数据。

第五章 总结与展望

5.1 总结

针对传统的皮肤黑色素瘤病理诊断无法对肿瘤组织进行定量分析的问题,本文将显微高光谱成像技术应用于皮肤黑色素瘤的识别和定量化分析。首先,研究了皮肤颗粒层的分割问题;其次,研究了恶性黑色素细胞的分割问题,并在此基础上,定量的计算出肿瘤入侵深度;最后研究了肿瘤区域的分类问题。实验表明,本文提出的方法具有较好的皮肤黑色素瘤识别精度。本文完成的研究工作如下:

首先,为了定量化的计算出皮肤黑色素瘤的入侵深度,需要分别分割出皮肤颗粒层和恶性黑色素瘤细胞。因此,本文针对皮肤颗粒层的分割问题,提出了基于 KMNF 的分割方法,对应文中 3.1.1 章节。在该方法中,分别分析了主成分分析(PCA)、最小噪声分离(MNF)、核最小噪声分离(KMNF)原理,并最终选取了 KMNF 来提取显微高光谱图像主要特征并分离图像中的噪声。同时设计了多尺度形态学滤波算子来提取皮肤颗粒层的主要形态特征,并应用水平集分割方法来得到颗粒层的形态轮廓。实验结果显示,该方法能够有效地分割皮肤颗粒层,为计算皮肤黑色素瘤入侵深度提供更准确的起始边界。

其次,本文针对恶性黑色素细胞的分割问题,提出了基于特征光谱监督的最小二乘支持向量机(CSS-LSSVM)的分割方法,对应文中 3.1.2 章节。在该方法中,使用最小二乘支持向量机(LSSVM)算法来建立肿瘤分割模型。为了提高模型的识别精度,在传统的 LSSVM 基础上,提出了特征光谱监督策略对 LSSVM 模型进行再分割。实验表明,该方法对皮肤黑色素瘤样本中的恶性黑色素细胞分割精度较高。

最后,本文针对肿瘤区域的分类问题,采用了基于粒子群优化的极限学习机(PSO-ELM)分类算法,对应文中 3.2 章节。在该方法中,使用了极限学习机(ELM)来建立肿瘤区域识别模型。在极限学习机的参数寻优中,使用了粒子群(PSO)优化算法来寻找 ELM 的更优参数,提高了 ELM 的分类精度。实验结果表明,本

文提出的基于 PSO-ELM 的分类方法能够有效的识别出样本中更多的肿瘤区域，且分类速度较快。

基于以上的算法理论研究，以皮肤黑色素瘤样本进行实验对比，以图表形式展示了每类样本的实验结果，并进行了讨论，对应文中第四章。实验得到的主要结论有：基于 KMNF 的分割方法对皮肤颗粒层的识别精度相比 PCA 和 MNF 更高；基于特征光谱监督的 LSSVM 分割方法相比 SVM，对样本中皮肤恶性黑色素细胞分割精度更高；基于 PSO-ELM 分类方法相比 SVM 分类方法，能识别出更多的肿瘤区域，分类速度更快，在皮肤黑色素瘤识别中，实用性更强。同时，根据皮肤颗粒层和恶性黑色素细胞的分割结果，本文提出的皮肤黑色素瘤入侵深度的测量方法能够有效地计算入侵深度。

综上所述，本文的实验样本均通过显微高光谱成像系统采集，结合皮肤黑色素瘤样本的特性，提出了三种显微高光谱图像处理方法，实现了样本中皮肤黑色素瘤的识别，并为皮肤黑色素瘤的病理诊断提供了定量化参数。证明了显微高光谱成像技术在皮肤黑色素诊断中的可行性，以及将显微高光谱成像技术作为病理诊断的辅助技术是可实现的。

5.2 展望

本文使用的皮肤黑色素瘤样本，均为显微高光谱成像系统采集，该系统可选的放大倍数为 40X、100X、200X、400X、1000X，针对本文的研究目的，本文使用的样本放大倍数为 100X 和 200X，在下一步研究中，可对其他放大倍数下的皮肤黑色素瘤样本进行研究。

本文提出的基于 KMNF 分割方法能够有效地分割皮肤颗粒层，但由于不同的样本颗粒层的厚度不一致，因此，在 KMNF 处理后的波段中，颗粒层的主要特性集中在 4-7 波段，在下一步研究中，可以经过大量实验对颗粒层的形态特性统一化，并设计参数自动选出颗粒层主要形态存在的波段。

皮肤黑色素瘤样本类型多样，本文中仅选取了三种常见样本类型进行研究，在下一步研究中，可以对更多不常见的皮肤黑色素瘤样本进行研究。现已有较多学者将显微高光谱成像技术应用在肿瘤的识别中，但少有对皮肤黑色素瘤的研究。

因此,本文的研究证明了显微高光谱成像技术能够有效地识别样本中的皮肤黑色素瘤及定量化,从而为显微高光谱成像技术辅助皮肤黑色素瘤的病理诊断的实现奠定了基础。在下一步研究中,可结合更多的病理诊断需求,进一步寻找更多的方法,为皮肤黑色素瘤的病理诊断提供更多定量化参数,从而造福于全人类。

参考文献

- [1]. Ferlay J, Soerjomataram I, Dikshit R, et al. Cancer incidence and mortality worldwide: sources, methods and major patterns in GLOBOCAN 2012 [J]. International Journal of Cancer, 2015, 136(5):E359-E386.
- [2]. Berwick M, Wiggins C. The current epidemiology of cutaneous malignant melanoma [J]. Frontiers in Bioscience A Journal & Virtual Library, 2006, 11(11):1244.
- [3]. Erdmann F, Lortet-Tieulent J, Schüz J, et al. International trends in the incidence of malignant melanoma 1953–2008—are recent generations at higher or lower risk? [J]. International Journal of Cancer, 2013, 132(2):385-400.
- [4]. 郝捷, 陈万青, 2014 中国肿瘤登记年报. 2015: 清华大学出版社
- [5]. 唐智柳, 石建伟, 蔡美玉, 等. 中国皮肤黑色素瘤发病及其影响因素分析[J]. 中国肿瘤, 2014, 23(10):829-833.
- [6]. 黄晓赤, 罗克枢. 皮肤黑色素瘤的诊断、预后及预防[J]. 现代临床医学, 2012, 38(3):237-238.
- [7]. 童庆禧, 张兵, 郑兰芬. 高光谱遥感:原理、技术与应用[M]. 高等教育出版社, 2006.
- [8]. 吴昊. 高光谱遥感图像数据分类技术研究[D]. 国防科学技术大学, 2004.
- [9]. 齐滨. 高光谱图像分类及端元提取方法研究[D]. 哈尔滨工程大学, 2012.
- [10]. Lee Z, Carder K L. Hyperspectral Remote Sensing [J]. Current Science, 2012, 94(9):1115-1116.
- [11]. 张婷婷. 基于 PLS 模型的农业土壤成分高光谱遥感反演研究[D]. 吉林大学, 2010.
- [12]. 龚绍琦, 王鑫, 沈润平, 等. 滨海盐土重金属含量高光谱遥感研究[J]. 遥感技术与应用, 2010, 25(2):169-177.
- [13]. 迟光宇, 刘新会, 刘素红, 等. 环境污染监测中的植物光谱效应研究[J]. 环境科学与技术, 2005, 28(b06):16-19.
- [14]. Barber P R, Vojnovic B, Atkin G, et al. Applications of cost-effective spectral imaging microscopy in cancer research [J]. Journal of Physics D Applied Physics, 2003, 36(14):1729-1738.
- [15]. Beach J M, Ning J F, Khoobehi B. Hyperspectral Algorithm for Mapping Tissue Oxygen Saturation[C]// Signal Processing Symposium, 2006. NORSIG 2006. Proceedings of the, Nordic. IEEE, 2006:142-145.
- [16]. Dicker D T, Lerner J, Van B P, et al. Differentiation of normal skin and melanoma using high resolution hyperspectral imaging [J]. Cancer Biology & Therapy, 2006, 5(8):1033-1038.
- [17]. Akbari H, Halig L V, Zhang H, et al. Detection of Cancer Metastasis Using a Novel Macroscopic Hyperspectral Method [J]. Proceedings of SPIE, 2012, 8317(3):831711.
- [18]. 李庆利, 肖功海, 薛永祺, 等. 基于显微高光谱成像的人血细胞研究[J]. 光电工程, 2008, 35(5):98-101.
- [19]. Kong S G, Chen Y R, Kim I, et al. Analysis of hyperspectral fluorescence images for poultry skin tumor inspection [J]. Appl Opt, 2004, 43(4):824-833.
- [20]. 宋颖, 欧阳汉, 叶枫, 等. MRI 计算机辅助诊断系统对不同经验医师鉴别乳腺小肿块良恶性的价值[J]. 放射学实践, 2016, 31(7):638-643.

- [21].周雪, 陈光意, 张建民,等. 应用血红蛋白的拉曼光谱进行食管癌诊断的研究[J]. 光谱学与光谱分析, 2013, 33(11):2989-2992.
- [22].Thomas L, Puig S. Dermoscopy, Digital Dermoscopy and Other Diagnostic Tools in the Early Detection of Melanoma and Follow-up of High-risk Skin Cancer Patients [J]. Acta Derm Venereol, 2017, 97.
- [23].Kim S, Cho D, Kim J, et al. Smartphone-based multispectral imaging: system development and potential for mobile skin diagnosis [J]. Biomedical Optics Express, 2016, 7(12):5294.
- [24].王婷, 后桂荣, 张宁,等. 基于激光共聚焦显微镜图像的黑色素瘤计算机辅助诊断算法研究[J]. 中国医学影像学杂志, 2013(2):130-133.
- [25].胡言广. 黑色素瘤图像特征提取算法研究[D]. 电子科技大学, 2015.
- [26].Nagaoka T, Nakamura A, Okutani H, et al. A possible melanoma discrimination index based on hyperspectral data: a pilot study [J]. Skin Research & Technology, 2012, 18(3):301-310.
- [27].Nagaoka T, Nakamura A, Okutani H, et al. Hyperspectroscopic screening of melanoma on acral volar skin [J]. Skin Research & Technology, 2013, 19(1):e290–e296.
- [28].Nagaoka T, Kiyohara Y, Koga H, et al. Modification of a melanoma discrimination index derived from hyperspectral data: a clinical trial conducted in 2 centers between March 2011 and December 2013 [J]. Skin Research & Technology, 2015, 21(3):278-283.
- [29].Zheludev V, Pölönen I, Neittaanmäki-Perttu N, et al. Delineation of malignant skin tumors by hyperspectral imaging using diffusion maps dimensionality reduction [J]. Biomedical Signal Processing & Control, 2015, 16(1):48-60.
- [30].Li J, Marpu P R, Plaza A, et al. Generalized Composite Kernel Framework for Hyperspectral Image Classification [J]. IEEE Transactions on Geoscience & Remote Sensing, 2013, 51(9):4816-4829.
- [31].魏峰, 何明一, 冯燕,等. 基于矩阵分解的高光谱数据特征提取[J]. 红外与毫米波学报, 2014, 33(6):674-679.
- [32].Levenson R, Beechem J, Mcnamara G. Modern Trends in Imaging X: Spectral Imaging in Preclinical Research and Clinical Pathology [J]. Analytical Cellular Pathology, 2012, 35(5-6):339.
- [33].Manea D. Hyperspectral Imaging in the Medical Field: Present and Future [J]. Applied Spectroscopy Reviews, 2014, 49(6):435-447.
- [34].江厚敏, 梅洁, 胡响祥,等. 高光谱成像医学诊断的探讨[J]. 中国医学物理学杂志, 2013, 30(3):4148-4152.
- [35].Li Q, Chang L, Liu H, et al. Skin cells segmentation algorithm based on spectral angle and distance score [J]. Optics & Laser Technology, 2015, 74:79-86.
- [36].易伟松. 高光谱成像诊断胃癌组织研究进展[J]. 中国医学物理学杂志, 2016, 33(8):788-792.
- [37].Akbari H, Kosugi Y, Kojima K, et al. Blood vessel detection and artery-vein differentiation using hyperspectral imaging [C]// International Conference of the IEEE Engineering in Medicine & Biology Society. Conf Proc IEEE Eng Med Biol Soc, 2009:1461.
- [38].Zherdeva L A, Alonova M V, Myakinin O O, et al. Hyperspectral imaging of skin and lung cancers [C]// Biophotonics: Photonic Solutions for Better Health Care V. Biophotonics: Photonic Solutions for Better Health Care V, 2016:98870S.
- [39].Tsapras A, Emmanouil T, Emmanouil P, et al. Hyperspectral imaging and spectral classification for assisting in vivo diagnosis of melanoma precursors: preliminary results

- obtained from mice [C]// IEEE International Conference on Imaging Systems and Techniques. IEEE, 2016:379-383.
- [40]. Chung H, Lu G, Tian Z, et al. Superpixel-based spectral classification for the detection of head and neck cancer with hyperspectral imaging [J]. Proc Spie Int Soc Opt Eng, 2016, 9788:978813.
- [41]. Fei B, Lu G, Wang X, et al. Tumor margin assessment of surgical tissue specimen of cancer patients using label-free hyperspectral imaging [C]// SPIE BiOS. 2017:100540E.
- [42]. 李庆利. 显微高光谱医学成像机理及应用研究[D]. 上海交通大学, 2006.
- [43]. Li Q, Zhou M, Liu H, et al. Red Blood Cell Count Automation Using Microscopic Hyperspectral Imaging Technology [J]. Applied Spectroscopy, 2015, 69(12):1372.
- [44]. Li Q, Wang Y, Liu H, et al. A combined spatial-spectral method for automated white blood cells segmentation [J]. Optics & Laser Technology, 2013, 54(32):225-231.
- [45]. 刘洪英, 李庆利, 顾彬, 等. 新型分子高光谱成像系统性能分析及数据预处理[J]. 光谱学与光谱分析, 2012, 32(11):3161-3166.
- [46]. 周显. 优良病理组织切片制作方法[J]. 临床医学, 2009, 29(8):108-109.
- [47]. Kambhatla N, Leen T K. Dimension Reduction by Local Principal Component Analysis [J]. Neural Computation, 1997, 9(7):1493-1516.
- [48]. Green A A, Berman M, Switzer P, et al. A transformation for ordering multispectral data in terms of image quality with implications for noise removal [J]. IEEE Transactions on Geoscience & Remote Sensing, 1988, 26(1):65-74.
- [49]. Sasaki N, Fukuda M, Kimoto K, et al. Characterization of vascular structures and skin bruises using hyperspectral imaging, image analysis and diffusion theory [J]. Journal of Biophotonics, 2010, 3(1 - 2):53-65.
- [50]. 汤春明, 许东滨, 马玲, 等. 神经元干细胞序列图像的结合局部灰度阈值的水平集分割算法[J]. 计算机辅助设计与图形学学报, 2010, 22(8):1279-1285.
- [51]. Osher S, Sethian J A. Fronts propagating with curvature-dependent speed: algorithms based on Hamilton-Jacobi formulations [M]. Academic Press Professional, Inc. 1988.
- [52]. 高晶, 毕笃彦, 赵晓林. 融合边缘片断与水平集分割的目标跟踪算法[J]. 西安电子科技大学学报(自然科学版), 2011, 38(6):146-151.
- [53]. 王晓峰. 水平集方法及其在图像分割中的应用研究[D]. 中国科学技术大学, 2009.
- [54]. 张治国, 周越, 谢凯. 一种基于 Mumford-Shah 模型的脑肿瘤水平集分割算法[J]. 上海交通大学学报, 2005, 39(12):1955-1958.
- [55]. Chan T F, Vese L A. Active Contour Without Edges [J]. IEEE Transactions on Image Processing, 2001, 10(2):266-277.
- [56]. Boutaouche F, Benamrane N. Diagnosis of breast lesions using the local chan-veese model, hierarchical fuzzy partitioning and fuzzy decision tree induction [J]. Iranian Journal of Fuzzy Systems, 2017.
- [57]. Cortes C, Vapnik V. Support-Vector Networks [J]. Machine Learning, 1995, 20(3):273-297.
- [58]. Suykens J A K, Vandewalle J. Least Squares Support Vector Machine Classifiers [J]. Neural Processing Letters, 1999, 9(3):293-300.
- [59]. 阎威武, 邵惠鹤. 支持向量机和最小二乘支持向量机的比较及应用研究[J]. 控制与决策, 2003, 18(3):358-360.
- [60]. 董春曦, 饶鲜, 杨绍全, 等. 径向基支持向量机推广能力快速估计算法[J]. 西安电子科技大学学报(自然科学版), 2004, 31(4):557-561.

- [61].Heermann P D, Khazenie N. Classification of multispectral remote sensing data using a back-propagation neural network [M]// Distributed Computing and Networking. Springer Berlin Heidelberg, 2006:479-490.
- [62].Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors [M]// Neurocomputing: foundations of research. MIT Press, 1988:533-536.
- [63].Huang G B, Zhu Q Y, Siew C K. Extreme learning machine: a new learning scheme of feedforward neural networks [C]// IEEE International Joint Conference on Neural Networks, 2004. Proceedings. IEEE, 2005(2):985-990.
- [64].Huang G B, Zhu Q Y, Siew C K. Extreme learning machine: Theory and applications [J]. Neurocomputing, 2006, 70(1):489-501.
- [65].Xu H, Berendt R, Jha N, et al. Automatic Measurement of Melanoma Depth of Invasion in Skin Histopathological Images [J]. Micron, 2017, 97:56.
- [66].Mokhtari M, Rezaeian M, Gharibzadeh S, et al. Computer aided measurement of melanoma depth of invasion in microscopic images[J]. Micron, 2014, 61(6):40.
- [67].郭军. 恶性黑色素瘤治疗的新进展[J]. 临床肿瘤学杂志, 2007, 12(12):881-884.
- [68].Sebastian G. Cutaneous malignant melanoma. Excision margins and lymph node dissections [J]. Hautarzt, 2006, 57(9):756-763.
- [69].Lens M B, Dawes M, Goodacre T, et al. Excision Margins in the Treatment of Primary Cutaneous Melanoma: A Systematic Review of Randomized Controlled Trials Comparing Narrow vs Wide Excision [J]. Archives of Surgery, 2002, 137(10):1101-5.

致谢

时间就这么悄悄的溜走了，我也终于写到了致谢，心里的感受很矛盾，既有开心也有难过，开心的是近 20 年的求学生涯终于要画上一个句号，我也将开始另一个阶段的生活，难过的是，我将要离开这个我待了七年的校园，这个让我慢慢长大的校园。看着自己在这个校园里，从满满的胶原蛋白到眼角的泛起细纹，不禁感叹，时间过得太快了。感谢我身边的每一个人。

首先，我要感谢我的导师李庆利教授。李老师知识渊博，学术严谨，论文从开题到定稿，都离不开李老师的细心指导和帮助。我觉得李老师是一位特别好的老师，尊重我们的兴趣爱好，给予我们很大的空间去发挥我们自身的特长。三年的学术研究中，他一步一步引导我发现自己喜欢做什么，鼓励并信任我，这给与我对学术研究的极大自信。研究生生涯中最大的幸运莫过于选择李老师做我的导师。同时，感谢实验室的周梅老师，一直以来，我都把周老师当大姐姐看待，能跟她讨论很多问题，在三年的学术研究中，周老师总会给我另外一个视角去发现学术魅力，在生活中，周老师也会教给我很多人生道理，受益良多。也要十分感谢温州医学院附属第二医院的罗老师和吴老师，感谢老师们为本论文提供的医学理论知识指导。

其次，我要感谢我的家人和朋友。感谢爸爸妈妈的养育之恩，感谢姐姐陪我一起长大。感谢爸爸为了整个家辛勤的工作，同时供我和姐姐上大学的经济重担压在他一个人的肩上，从不抱怨；感谢贤良淑德的妈妈从小对我的呵护，给了我一个良好的心理成长环境，也给了我一个很好的学习榜样；感谢姐姐从小的陪伴，虽然我们小时候经常打架，但是我依旧很爱你。感谢我的发小赖姝荔和陈红艳，虽然我们不在一个城市，虽然我们一年见一次，但我们的感情依旧如故。感谢陪伴了我七年的同班同学高飞和申晚霞，这么多年有你们的陪伴，我觉得很幸福。

然后，我要感谢实验室的学长张洋、高云峰、胡恒、翟宙洋、曹阳，学姐房娟、林维维，同学王倩、陈雪蓉，学弟袁晨、肖志睿、顾钦华、徐怀奇、陈文杰，

学妹郑欣、刘茜、严斯能、宋璟、段依潘、张晴，我想我会时常怀念我们在实验室一起采数据，一起讨论算法，一起分零食的日子，有你们的监督和陪伴，在实验室学习的日子充实且快乐。

同时，我要特别感谢刘正峰学长对论文细节的把关，感谢你抽出自己的休息时间帮我逐句检查，也要感谢你这近两年的陪伴，我们斗智斗勇，相爱相杀，彼此都变成了更好的自己。虽然我们总是习惯性的对抗，但是我相信，我们都很了解彼此，以后我们一定会是很好的朋友。

此外，我也要特别感谢华东师范大学的心理咨询中心的所有老师和同学，感谢老师和同学对我的帮助，七年里，我参加了很多心理咨询中心的活动，每个学期的咨询仿佛成了我的必修课，我喜欢在那里释放我的压力和困惑，我喜欢在那里慢慢的了解自己，调整自己，做更好的自己。因为有心理咨询中心的存在，才有现在乐观开朗的我，由衷地感谢师大给学生提供了这样一个平台。

最后，我对各位评审专家和老师表示衷心的感谢！愿你们今后的每一天，都幸福美满！

攻读硕士学位期间发表的学术论文

- [1]. Huang Y, Zhou M, Li Q, et al. A multi-dimensional microscopic imaging system and reconstruction methods[C]// International Congress on Image and Signal Processing, Biomedical Engineering and Informatics. IEEE, 2017:576-580.
- [2]. 黄怡, 胡恒, 江霞,等. 基于蓝牙 4.0 的智能物流监控系统设计[J]. 测控技术.2018.(已收录待见刊)
- [3]. 罗旭, 田望晓, 黄怡,等. 基于显微高光谱成像技术的真皮替代物血管化进程分析[J]. 红外与毫米波学报, 2018, 37(1):98-105.

攻读硕士学位期间申请的发明专利

[1]. 华东师范大学. 物流跟踪监控防盗装置.

专利号: ZL 2015 1 0585829.7, 申请日: 2015.09.16, 授权公告日: 2017.11.24.

[2]. 华东师范大学. 网球训练矫正装置.

专利号: ZL 2015 1 0860104.4, 申请日: 2015.12.01., 授权公告日: 2017.11.24.

攻读硕士学位期间参与的科研项目

- [1]. 国家自然科学基金：微阵列光谱成像的肿瘤多靶点多时相虚拟显微分析研究.
项目批准号：61377107.
- [2]. 上海市科委重点科技攻关项目：融合北斗的物流跟踪与监控关键技术及示范应用.
项目批准号：16511103400.
- [3]. 上海市科技成果转化和产业化项目：高分卫星遥感在长江河口滩涂水沙和生态监测中的应用研究
项目批准号：18511102500.